idea 003 的统计量

PMI 分解与前缀兼容度：测什么、怎么测、看到什么说明什么

目录

0. 一页故事
1. 记号
2. 统计量地图
3. 第 0 步：恒等式检查
4. 逐 token 特征 F0–F7
5. 检验 H2：分支续写
6. 检验 H3：反思词的 PMI
7. 检验 H1：特权信息的类型
8. 训练中监控
9. 混杂、判据与执行计划

附录：缩写、符号索引、参考文献

每个符号都在使用前定义。完整的通用统计量见 main-zh.pdf；这份只保留与 idea 003 直接相关的部分。

0. 一页故事

一页故事：四个现象，可能是同一个量

已有论文里的四个现象

1. **反思词消失**：thinking 模型少写 wait、but；给完整解法比只给答案退化更多（Rethinking OPSD）。
2. **风格漂移**：学生学到的是“看过参考的写法”（RLCSD）。
3. **老师前面不可靠、后面可靠**（PW-OPSD）。
4. **前缀越长，老师越难纠正**（LGR），与 3 相反。

idea 003 的解释

- 自蒸馏的打分，主要成分是**老师看了答案之后，对这个词的看法变了多少**，即点互信息（PMI）。
- 把它沿前缀累加，得到**前缀兼容度**：学生目前写的这段和答案对不对路。

三个假设：**H1** 答案是学生推不出来的、任务又需要试错时，OPSD 有害。**H2** 老师可不可靠看兼容度，不看位置。**H3** 反思词只在对路的前缀上被压制。

全部是待检验的假设，尚无实验。最接近的已有工作是 TrOPD 和 Many Faces，只做了定性讨论。

1. 记号

记号（1/4）：对象与分布

符号	含义
x	题目
z	特权信息：最终答案或完整参考解法，只给老师看
$y = (y_1, \ldots, y_L)$；L	学生的一条回答；它的 token 数
$h_t = (y_1, \ldots, y_{t-1})$；$t/L$	位置 t 之前的前缀；相对位置
θ；θ_0；$\bar{\theta}$	学生的当前参数；初始参数；老师参数（同步时等于采样时刻的 θ，也可以冻结为 θ_0 或取 EMA）
$\pi_\theta(\cdot \mid \ldots)$，$\pi_{\bar{\theta}}(\cdot \mid \ldots)$	参数为 θ 或 $\bar{\theta}$ 的同一个网络，在竖线右边的上下文下对下一个 token 的分布
$p_t = \pi_\theta(\cdot \mid x, h_t)$；$q_t = \pi_{\bar{\theta}}(\cdot \mid x, z, h_t)$	学生分布；老师分布（看 z）
$q_t^0 = \pi_{\bar{\theta}}(\cdot \mid x, h_t)$	老师分布（不看 z，与学生用同一个 prompt 模板）
$d_t = \log q_t(y_t) - \log p_t(y_t)$	OPSD 的逐 token 训练信号；log 为自然对数
$c \in \{0, 1\}$	回答是否正确（1 为正确）

记号（2/4）：把训练信号拆成两半

$$d_t = \underbrace{\log q_t(y_t) - \log q_t^0(y_t)}_{\mathrm{PMI}_t} + \underbrace{\log q_t^0(y_t) - \log p_t(y_t)}_{\Delta_t^{\mathrm{snap}}}$$

- PMI_t（得名于点互信息）：看到 z 让老师对 y_t 的 log 概率提高了多少，即**答案对这个词的表态**。
- Δ_t^{snap}（快照差）：老师参数与学生当前参数的差别，和 z 无关。
- 老师同步时，一步中第一个 mini-batch 上 $\Delta_t^{\mathrm{snap}} = 0$，所以 $d_t = \mathrm{PMI}_t$；之后 $\Delta_t^{\mathrm{snap}} = -\log r_t$，其中 $r_t = p_t(y_t)/q_t^0(y_t)$ 就是 PPO 的重要性比率，通常接近 1。
- 老师冻结或取 EMA 时，Δ_t^{snap} 会随训练变大，作用相当于把学生拉回老师参数。

记号（3/4）：前缀兼容度

对 $\pi \in \{\pi_\theta, \pi_{\bar{\theta}}\}$，前缀的概率为 $\pi(h_t \mid x) = \prod_{u=1}^{t-1} \pi(y_u \mid x, h_u)$，上下文中带 z 时同理。由链式法则：

$$S_t = \sum_{u=1}^{t-1} \mathrm{PMI}_u = \log \frac{\pi_{\bar{\theta}}(h_t \mid x, z)}{\pi_{\bar{\theta}}(h_t \mid x)}, \qquad S_1 = 0$$

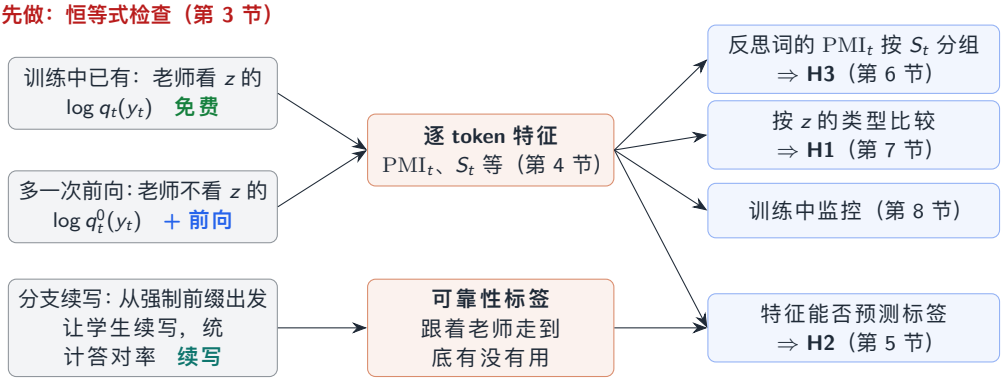
- $S_t > 0$：看过答案时这段前缀更可能出现，学生沿着 z 的路线走。
- $S_t < 0$：前缀已经离开这条路线，例如换了方法或出了错。
- $S_t \approx 0$：还看不出来，多在开头。
- 令 $h_{L+1} = y$：$\pi(y \mid x)$ 是整段回答的概率，S_{L+1} 是整段回答的兼容度。

记号（4/4）：其他符号与统计工具

符号	含义
$\mathcal{V}$； $a \in \mathcal{V}$	词表；一个 token
$\hat{y}_t = \arg\max_a q_t(a)$； $T_m(q)$	老师在位置 t 最想写的 token；分布 q 下概率最高的 m 个 token
$\mathcal{H}(q) = -\sum_a q(a) \log q(a)$	分布 q 的熵
$D_{\mathrm{KL}}(p\|q) = \sum_a p(a) \log \frac{p(a)}{q(a)}$	KL 散度
$\mathcal{W}$	反思词表：wait、but、hmm、let me check、actually 等（预先固定）
z^+； z^-	正确参考（$z^+ = z$）；同一模板下的错误参考
$\mathbb{E}$, Pr； Var, Cov	期望、概率；方差、协方差
AUROC($s \to c$)	随机取一正一负两个样本，正例分数 s 更高的概率；0.5 等于瞎猜
ρ_{S}； corr	Spearman 秩相关；Pearson 相关
p_α	第 α 百分位数，例如 p_{50} 是中位数

2. 统计量地图

统计量地图：数据从哪来，回答哪个假设



成本标签：**免费** 训练中已经算好　**＋ 前向** 多一次前向　**全词表** 需要整个词表上的概率　**续写** 学生续写　**离线** 在保存的数据上离线算　**评测** 评测　**＋ 训练** 额外训练

3. 第 0 步：恒等式检查

第 0 步（E0）：先确认 PMI 算对了

在约 20 个回答上做以下检查。任何一项不通过，后面所有的 PMI 都可能只是模板或分词错误。

1. **求和恒等式。**两种 prompt 下整段回答的 log 概率单独计算，检查

$$\sum_{t=1}^{L} \mathrm{PMI}_t = \log \pi_{\bar{\theta}}(y \mid x, z) - \log \pi_{\bar{\theta}}(y \mid x)$$

   每 token 的平均误差应小于 10^{-3}。

2. **token 相同。**回答的 token id 在两种模板下完全相同，不能各自重新分词。

3. **快照差为 0。**老师同步时，一步中第一个 mini-batch 上的 Δ_t^{snap} 应恰好为 0，即训练日志里的 d_t 等于离线重算的 PMI_t。不为 0 说明两种模板除了 z 之外还有别的差异。

成本：＋ **前向** 一次。

4. 逐 token 特征 F0–F7

逐 token 特征：F0–F7

编号	特征	定义	直观含义	成本
F0	相对位置（基线）	$(t-0.5)/L$	写到哪里了	免费
F1	老师熵（基线）	把 q_t 限制在 $T_{16}(q_t)$ 上、重新归一化后的 $\mathcal{H}$（PW-OPSD 口径）	老师自己有多犹豫	全词表
F2	PMI	PMI_t	答案对这个词的表态	免费 / + 前向
F3	累计 PMI	S_t	前缀和答案对不对路	同 F2
F4	平均累计 PMI	$S_t/(t-1)$，$t \geq 2$	去掉长度累积后的兼容度	同 F2
F5	局部特权散度	在 $T_{64}(q_t) \cup T_{64}(q_t^0)$ 上、其余 token 合为一个桶时的 $D_{\mathrm{KL}}(q_t \| q_t^0)$	答案在这个位置改变了老师多少	全词表
F6	候选 PMI	对 $a \in T_3(q_t)$ 算 $\log q_t(a) - \log q_t^0(a)$，取最大值和均值	老师的候选词有多依赖答案	全词表
F7	对比累计 PMI	$\sum_{u=1}^{t-1} \left[\log \pi_{\bar{\theta}}(y_u \mid x, z^+, h_u) - \log \pi_{\bar{\theta}}(y_u \mid x, z^-, h_u) \right]$	扣掉“看过某个参考”的风格后的兼容度	+ 前向

老师同步时 F2–F4 免费，否则需多一次不带 z 的前向。

5. 检验 H2：分支续写

分支续写标签：在这个位置，跟着老师走有没有用？

主干（spine）：一条固定的学生回答。$h \oplus a$：前缀 h 后接 token a。$\hat{V}(h)$：从 h 出发、学生**不看** z 续写 n_{roll} 次，答对的比例。

E1：做对的主干（沿用 PW-OPSD 协议）

每题最多取 F1 最高的 5 个位置；对每个 $a \in T_3(q_t)$ 强制续写；$n_{\text{roll}} = 6$。
多解（diversity）：至少两个候选 $\hat{V}(h_t \oplus a) \geq 0.75$，选哪个都能做对。
真不确定（real-uncertain，正例）：所有候选及其均值都低于 0.40。
其余为**灰区**，不参与 AUROC。

E2：做错的主干（帮助度）

每条主干在 t/L 上均匀取 5 个位置；$n_{\text{roll}} = 8$：

$$\Delta_t = \hat{V}(h_t \oplus \hat{y}_t) - \hat{V}(h_t \oplus y_t)$$

$\Delta_t > 0$：老师最想写的词对看不到 z 的学生有帮助。$\hat{y}_t = y_t$ 时记 $\Delta_t = 0$，并报告这类位置的比例。

测试时学生看不到 z，所以续写也不给。成本 **续写**：E1 约题数 $\times 90$ 次续写，E2 约题数 $\times 80$ 次。

H2 的统计量（1/2）：E1，做对的主干

统计量	怎么算	成本	回答的问题
锚点复现	F0 的 AUROC，与 PW-OPSD 的 0.83（题目级 bootstrap CI $[0.66, 0.95]$，8 个正例）对照。换模型时以同一批数据上重测的值为基线。	续写	标签口径和 PW-OPSD 一致吗?
单特征 AUROC	F0–F7 各自区分真不确定与多解的 AUROC；先在每道题内减去均值；题目级 bootstrap 95% CI（2000 次）。	续写	哪个特征最能预测老师可不可靠?
增量价值	按题目分 5 折的逻辑回归：F0 加一个特征的留出 AUROC，减去只用 F0 的；附 bootstrap CI。	离线	兼容度有没有位置之外的信息?
按位置分层	把 t/L 三等分，在每一段内算 F3、F5 的 AUROC。	离线	兼容度是不是只是位置的替身?
正例数量	真不确定位置的个数（目标至少 40）；灰区比例。	免费	样本够不够下结论?

H2 的统计量（2/2）：E2，做错的主干

统计量	怎么算	成本	回答的问题
帮助度与兼容度	$\rho_S(\Delta_t, S_t)$；控制 t/L 后的偏相关（两者分别对 t/L 回归后，残差之间的相关）。	续写	走偏的前缀上老师是否更失真？（LGR 的方向）
按 S_t 的符号分组	$S_t \geq 0$ 与 $S_t < 0$ 时 Δ_t 的均值及 CI。	续写	同上，更直观。
老师无异议的比例	$\hat{y}_t = y_t$ 的位置比例。	免费	多少位置老师本来就同意学生？
救回率	在 $\hat{V}(h_t) \leq 0.1$ 的位置上，$\hat{V}(h_t \oplus \hat{y}_t)$ 的均值。	续写	学生快要失败时，老师能救回来吗？
背书率	出错的一步：$\hat{V}(h_{t+1}) \leq \hat{V}(h_t) - 0.3$。其中 $\mathrm{PMI}_t > 0$ 的比例。	续写	老师会不会给出错的一步加分？

救回率和背书率的阈值（0.1、0.3）是这份 slides 补充的，可以调。$\hat{V}(h_t)$ 需要从 h_t 额外续写。做对与做错的主干选位置的规则不同，结果分开报告。

6. 检验 H3：反思词的 PMI

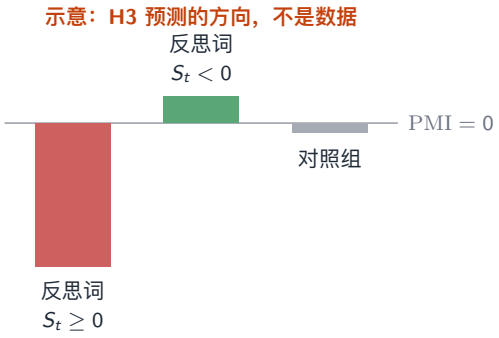
H3 的统计量（E3）：不需要续写，最便宜

知道答案的人不需要检查，所以在对路的前缀上 $\mathrm{PMI}_t(\text{wait}) < 0$；但学生走偏时，知道答案的人会要求回头看。

统计量	怎么算	成本	回答的问题
按对错分	$y_t \in \mathcal{W}$ 处 PMI_t 的均值与分布：做对 vs. 做错的回答。	免费 ＋ 前向	反思词在两类回答里待遇一样吗?
按兼容度分	做错的回答内部：$S_t \geq 0$ 段与 $S_t < 0$ 段的比较；差值的题目级 bootstrap CI。	免费 ＋ 前向	压制是否取决于前缀状态?
对照组	与反思词位置分布匹配、但不在 $\mathcal{W}$ 中的随机 token，同样分组。	免费 ＋ 前向	是不是走偏段所有词的 PMI 都偏高?
反思词频率	每 1000 token 中 $\mathcal{W}$ 里的词出现的次数，训练前后对比。	免费	压制有多严重（fork suppression）?

老师同步时用 免费，否则用 ＋ 前向。

H3：预测长什么样，以及已有证据



已有证据（Rethinking OPSD 图 5）

固定同一条学生轨迹，只切换老师看不看参考，对数比 $\log q - \log p$ 的变化：

But：$+0.95 \to -1.96$；　wait：$+0.37 \to -4.97$。

两者之差就是 PMI：wait 约 -5.3。

怎么读：红柱明显低于绿柱且 CI 不重叠 $\Rightarrow$ 支持 H3，值得按 S_t 屏蔽对反思词的负信号。两柱无差别 $\Rightarrow$ 压制与前缀状态无关。

7. 检验 H1：特权信息的类型

H1：特权信息何时可教

z 的类型	学生能否自己推出 z	例子	预测
计算型	能（多算几步就行）	Vision-OPD 裁剪、OPHSD harness、d-OPSD self-future	有益
信息型，任务短	不能，但不需要试错	GUI-SD 目标框、短预算 instruct 模型	有益
信息型，长推理	不能，且需要试错	thinking 模型 + 参考解法	**退化**，z 信息越多越严重

- **直觉**：学生能推出 z 时，模仿老师等于把“多算几步”存进参数；推不出时，老师从不需要探索和检查，学生只学到“不用试错”的姿态。
- **一致的证据**：Rethinking 中完整解法比只给答案退化更多；thinking 模型的反思明显减少，instruct 模型变化较小。
- 这就是机器人模仿学习中的 imitation gap（Learning by Cheating、ADVISOR）。

H1 的统计量

统计量	怎么算	成本	回答的问题
按 z 的类型比较 PMI	z 分别为仅最终答案、完整解法、提示：各自的 PMI_t 分布和反思词的 PMI_{t_0}。	+ 前向 每种	信息越多，对反思的惩罚越重?
按 z 的类型训练	每种 z 各训一次：留出题准确率、反思词频率。	+ 训练 评测	哪种 z 退化最多?
模型类型	thinking 模型与 instruct 模型，训练前后反思词频率的变化。	+ 训练	需要试错的模型是否更受伤?
准确率与预算	多个生成长度上限下的留出题准确率。	评测	预算越长是否越差?
探索差距	pass@K（K 次采样至少一次答对的比例）：pass@64 减 pass@1。	评测	探索是否被压缩?

跨任务比较（图像裁剪、GUI 定位等）需要在其他任务上实验，超出本诊断的范围。

8. 训练中监控

训练中监控（E4，1/2）：兼容度与反思

统计量	怎么算	成本	回答的问题
S_t 剖面	S_t 的 p_{10}、p_{50}、p_{90} 随 t/L 的变化；$S_t < 0$ 的 token 比例。	免费 + 前向	学生是否沿着 z 的路线走？这个比例随训练怎么变？
整段兼容度	做对与做错的回答上 S_{L+1} 的分布。	免费 + 前向	做对的回答是否更贴近 z？
反思词 PMI 曲线	每步 $y_t \in \mathcal{W}$ 处 PMI_t 的均值，按 S_t 的符号拆开。	免费 + 前向	压制在反思词变少之前就能看到吗？
反思词频率	每 1000 token 中 $\mathcal{W}$ 里的词数。	免费	fork suppression 本身。
信号与兼容度	$\mathrm{corr}(S_t, \lvert d_t \rvert)$。	免费 + 前向	不兼容的前缀上信号是否更极端？

老师同步时用 **免费**，冻结或 EMA 时需要 **+ 前向** 得到 q_t^0。不改损失，只加日志。

训练中监控（E4，2/2）：信号来源与漂移

统计量	怎么算	成本	回答的问题
方差分解	$\mathrm{Var}(d_t) =$ $\mathrm{Var}(\mathrm{PMI}_t) + \mathrm{Var}(\Delta_t^{\mathrm{snap}}) + 2\,\mathrm{Cov}(\mathrm{PMI}_t, \Delta_t^{\mathrm{snap}})$。	+ 前向	老师冻结或 EMA 时，信号来自答案，还是来自“拉回初始模型”?
序列级恒等式	老师同步时：$\mathbb{E}_{y\sim\pi_\theta(\cdot\mid x)}[S_{L+1}] = -D_{\mathrm{KL}}\big(\pi_\theta(\cdot\mid x)\,\|\,\pi_\theta(\cdot\mid x,z)\big)$，KL 在整段回答的分布上取。	免费	学生是否在整体上向“看过答案的自己”靠拢(风格漂移)?
对比 PMI	$\log\pi_{\tilde\theta}(y_t\mid x,z^+,h_t) - \log\pi_{\tilde\theta}(y_t\mid x,z^-,h_t)$，及其与 PMI_t 的相关。RLCSD、VA-OPD、VC-OPD 都用这类信号，区别只在 z^- 怎么选。	+ 前向	多少信号来自风格而不是内容?
答案泄漏	最终答案在 y 中首次出现的相对位置；y 与 z 共享的 4-gram 比例。	免费	学生是在推理还是在背 z?

解读上面这些量，需要同时看的背景曲线

统计量	怎么算	成本	回答的问题
师生差距	$-d_t$ 的均值（$D_{\mathrm{KL}}(p_t\|q_t)$ 的单样本估计），或直接算 $D_{\mathrm{KL}}(p_t\|q_t)$。	免费 / 全词表	学生是否在接近老师?
学生熵	$\mathcal{H}(p_t)$ 的均值；$\mathcal{H}(p_t) < 0.01$ 的 token 比例。	免费	是否熵坍缩?
长度与截断	L 的均值和 p_{90}；被生成上限截断的比例；做对与做错分开。	免费	回答在变长还是变短?
留出题准确率	pass@1 和 pass@K，按初始难度分桶。	评测	真的变强了吗?

完整的通用统计量（正确性检查、梯度、校准、表示等）见 main-zh.pdf 第一部分与 II.1。

9. 混杂、判据与执行计划

混杂与对照：哪些结果可能是假象

混杂	为什么是问题	对策
位置	S_t 是累加量，天然随 t 增长	增量检验与位置分层；F4 取平均
模板与风格	老师的模板本身会改变分布，与 z 的内容无关	F7 用 z^- 对比；E0 检查快照差为 0
选择偏差	做对与做错的主干选位置的规则不同	两类结果分开报告
答案 vs. 解法	PW-OPSD 诊断给的是答案，训练可能给完整解法	两种 z 都测
正例稀少	PW-OPSD 只有 8 个正例	只留初始通过率在 $[0.2, 0.8]$ 的题；不到 40 个正例不下结论
快照差	诊断时 $\bar{\theta} = \theta$，训练中未必	用 E4 检查结论能否迁移
贝叶斯解读	“S_t 是读完前缀后对 z 的后验提升”依赖一致的联合分布，LLM 不保证	只当直觉，以续写标签为准

预先写下的判据

结果	结论
E1：F3 或 F5 的 AUROC 不低于 F0，且增量的 CI 不含 0	支持 H2：兼容度提供位置之外的信息
E1：增量的 CI 含 0，但位置分层内 F3/F5 的 AUROC > 0.6	兼容度与位置大部分重合，H2 只部分成立
E1：位置分层内 F3/F5 的 AUROC ≈ 0.5	H2 不成立，位置效应另有原因
E2：控制 t/L 后，Δ_t 与 S_t 的偏相关明显为正	支持“偏离 z 的路线导致指导失真”
E2：Δ_t 与 S_t 无关	LGR 的衰减不能用兼容度解释
E3：$S_t < 0$ 段的反思词 PMI 明显高于 $S_t \geq 0$ 段	支持 H3：值得按前缀状态屏蔽
F7 优于 F3	风格是噪声来源，对比基线是必要的

正负结果都要保留。单个模型、单组题目的结果不能当作普遍结论。

执行计划：先做什么

最少要做的四件事

1. E0：恒等式检查。
2. 训练日志里加上 $\log q_t^0(y_t)$，得到 PMI_t 和 S_t。
3. E3：按 S_t 分组看反思词 PMI，不需要续写。
4. 阶段 A：60 道题跑 E1，先复现位置 AUROC。

诊断成立之后（未实现）

后验混合老师；兼容度门控（S_t 过低时减小特权信号的权重）。

分阶段

A. 60 道题，跑 E0 和 E1；位置 AUROC 与 PW-OPSD 相近，才比较新特征。

B. 只留初始通过率在 $[0.2, 0.8]$ 的题，扩到至少 40 个正例；跑完整的 E1–E3，z 取答案和完整解法两种。

C. 在正在进行的 OPSD 或 STOPD 训练中加入 E4 日志。

需要 dump 的字段

逐 token：t、$\log q_t(y_t)$、$\log q_t^0(y_t)$、$\log p_t(y_t)$、$y_t \in \mathcal{W}$ 标记。
逐回答：c、z 的类型、答案首次出现的位置。
逐分支：位置、强制的 token、n_{roll}、$\hat{V}$。

附录

缩写与符号索引

OPSD	在线自蒸馏：老师是看到 z 的学生自己
PMI	点互信息
EMA	指数滑动平均
PPO	近端策略优化
AUROC	ROC 曲线下面积
CI	置信区间
E0–E4	本 slides 的五组实验
H1–H3	三个假设（一页故事）
F0–F7	逐 token 特征（第 4 节）

符号	所在页
x, z, y, L, h_t	记号 1
$\theta, \theta_0, \bar{\theta}$	记号 1
$\pi_\theta, \pi_{\bar{\theta}}$	记号 1
p_t, q_t, q_t^0, d_t, c	记号 1
$\mathrm{PMI}_t, \Delta_t^{\mathrm{snap}}, r_t$	记号 2
$S_t, \pi(h_t \mid x)$	记号 3
$\mathcal{V}, a, \hat{y}_t, T_m$	记号 4
$\mathcal{H}, D_{\mathrm{KL}}, \mathcal{W}$	记号 4

符号	所在页
z^+, z^-	记号 4
$\mathbb{E}$, Pr, Var, Cov	记号 4
AUROC, ρ_{S}, corr, p_α	记号 4
$h \oplus a$, $\widehat{V}$, n_{roll}	分支续写
Δ_t	分支续写
K	H1

参考文献 i

- Rethinking On-Policy Self-Distillation for Thinking Models. arXiv:2607.05184, 2026.
- When Are Teacher Tokens Reliable? Position-Weighted On-Policy Self-Distillation for Reasoning (PW-OPSD). arXiv:2605.21606, 2026.
- RLCSD: Reinforcement Learning with Contrastive On-Policy Self-Distillation. arXiv:2606.11709, 2026.
- Your Teacher Can't Help You Here: Combating Supervision Fidelity Decay in On-Policy Distillation (LGR). arXiv:2605.30833, 2026.
- Trust Region On-Policy Distillation (TrOPD). arXiv:2606.01249, 2026.
- The Many Faces of On-Policy Distillation: Pitfalls, Mechanisms, and Fixes. arXiv:2605.11182, 2026.
- Visual-Advantage On-Policy Distillation for Vision-Language Models (VA-OPD). arXiv:2605.21924, 2026.
- VC-OPD: Visual Counterfactual On-Policy Distillation for Grounded Vision-Language Reasoning. arXiv:2610.14939, 2026.
- Vision-OPD: Learning to See Fine Details for Multimodal LLMs via On-Policy Self-Distillation. arXiv:2605.18740, 2026.
- Training with Harnesses: On-Policy Harness Self-Distillation for Complex Reasoning (OPHSD). arXiv:2605.08741, 2026.
- Learning from the Self-future: On-policy Self-distillation for dLLMs (d-OPSD). arXiv:2606.18195, 2026.

参考文献 ii

- Learn where to Click from Yourself: On-Policy Self-Distillation for GUI Grounding (GUI-SD). arXiv:2605.00642, 2026.
- Does On-Policy Distillation Need to Complete Every Rollout? (STOPD). Code: github.com/YouAreSpecialToMe/STOPD, 2026.
- D. Chen et al. Learning by Cheating. CoRL 2019. arXiv:1912.12294.
- L. Weihs et al. Bridging the Imitation Gap by Adaptive Insubordination (ADVISOR). NeurIPS 2021. arXiv:2007.12173.