OPSD 实验的统计量

OPD / OPSD 实验的通用统计量，以及检验 PMI / 前缀兼容度假设的统计量

目录

导读（6 页）：先看这里

第一部分：通用统计量

0. 设定、记号、成本标签
A. 正确性检查
B. 信号落在哪里
C. 估计量质量
D. 梯度与优化器
E. 校准与置信度
F. 表示与机制
G. 泛化、遗忘与鲁棒性
H. 实验严谨性

汇总

第二部分：idea 003（PMI 与兼容度）

II.0 记号与假设
II.1 训练健康度与任务指标
II.2 逐 token 信号
II.3 师生分布差距
II.4 PMI 分解与前缀兼容度
II.5 前缀可靠性：分支续写
II.6 推理行为与多样性
II.7 参数动态与成本
II.8 切片、执行计划与分阶段

每个符号都在使用前定义；附录列出缩写、符号索引和参考文献。

导读：先看这几页

导读（1/6）：一句话说清 OPSD

同一个模型扮演两个角色：

- **学生**：只看题目 x，自己写出解答 $y = (y_1, \ldots, y_L)$。写第 t 个词时，前面已经写下的部分记为 h_t，学生对下一个词的概率分布记为 p_t。
- **老师**：除了题目，还看到答案或参考解法 z；它在同一位置对下一个词的分布记为 q_t。

学生写完后，对其中每个词 y_t 打一个分（log 为自然对数）：

$$d_t = \log q_t(y_t) - \log p_t(y_t) \qquad = \text{看过答案的老师比学生更想写} y_t \text{ 多少}$$

- $d_t > 0$：训练加强这个词；$d_t < 0$：训练削弱这个词。
- 后面所有统计量都在回答两个问题：**这个打分靠不靠谱？训练有没有真的变好？**

导读（2/6）：第一部分其实只问四个问题

问题	看什么	怎么解读	详见
1. 训练健康吗?	学生分布与老师分布的 KL 散度、学生的熵、回答长度	KL 散度应下降；熵骤降说明模型变“死板”；长度暴涨或暴跌都要警惕	II.1，II.3
2. 真的变强了吗?	留出题上的 pass@1（单次答对率）和 pass@K（K 次采样中至少一次答对的比例）	pass@1 涨而 pass@K 跌：模型只是变保守了，没有学到新东西	II.1，G
3. 打分方向对吗?	答错的回答里，d_t 加起来是否偏负	应与最终对错大体一致；不一致说明老师在乱打分	C
4. 是不是在抄答案?	答案是否提前出现、推理是否变短、“wait”“but”这类反思词是否变少	老师看过答案，容易教学生“直接写答案、别想了”；长推理模型上最常见的退化	II.6

梯度噪声、有效秩、CKA、logit lens 等是**出了问题之后查原因**用的，第一轮实验可以先不看。

导读（3/6）：idea 003 第一步——把打分拆成两半

再算一个“老师**不看**答案”时对下一个词的分布，记为 q_t^0，就能把 d_t 拆开：

$$d_t = \underbrace{\log q_t(y_t) - \log q_t^0(y_t)}_{\mathrm{PMI}_t} + \underbrace{\log q_t^0(y_t) - \log p_t(y_t)}_{\Delta_t^{\mathrm{snap}}}$$

- PMI_t：看了答案之后，老师对这个词的看法变了多少。
- Δ_t^{snap}：老师用的是这一轮开始时的参数，而学生在这一轮里已经更新了几步。第一个 mini-batch 上它等于 0，一般很小。
- 所以打分几乎全部来自 PMI_t，也就是**答案带来的信息**。它偏好哪些词、压制哪些词，就是“答案”在教学生什么。

导读（4/6）：前缀兼容度 S_t 与假设 H2

把前面每个词的 PMI 累加起来，得到前缀兼容度：

$$S_t = \sum_{u=1}^{t-1} \mathrm{PMI}_u \quad = \text{看过答案的人比没看过的人更认同这段前缀多少}$$

S_t	含义	H2 的预测
≈ 0	还看不出学生要走哪条路（多在开头）	老师**不可靠**：把学生拽向参考解法，压掉其他正确思路
> 0	学生正沿着参考解法的路走	老师**可靠**
< 0	学生已经走偏（换了方法或出了错）	老师**失真**：好比拿对不上的标准答案批改作业

H2：老师准不准由 S_t 决定，而不是由“写到第几个词”决定。PW-OPSD 发现越往后老师越准，可能是因为它只看了做对的解答，而这些解答越往后越贴近参考解法。

导读（5/6）：H3、H1，以及怎么验证老师说得对不对

- **H3：反思词的符号翻转。**前缀对路时，知道答案的人不会说“等等，我检查一下”，所以 wait 的 PMI 为负，OPSD 会压制反思；前缀走偏时，知道答案的人反而会说“回头看看”，PMI 接近 0 或为正。
  若成立：要保护反思，应按前缀状态（S_t）屏蔽，而不是把 wait 列进保护词表。
- **H1：可推得性。**给学生自己也能推出的提示（例如图像裁剪），OPSD 有益；给学生推不出的信息（例如完整参考解法），在需要试错的长推理里反而退化：学生学会了“不用探索”。
- **分支续写：验证老师在某个位置说得对不对。**从同一段前缀出发，分别接上学生原来写的词和老师最想写的词，各让学生（不看答案）续写多次，比较最终答对率。老师的词答对率更高，就说明老师在这里说对了。这一步很贵，只抽几百个位置做（II.5）。

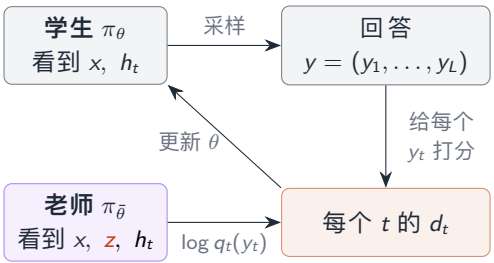
导读（6/6）：最少要做的四步

1. 训练时多做一次“老师不看答案”的前向，得到 q_t^0；PMI_t 和 S_t 随之而来，代价只是一次前向。
2. 盯住四条曲线：学生与老师分布的 KL 散度、学生的熵、回答长度、留出题上的 pass@1 与 pass@K。
3. 画一张图：按 S_t 的正、负、近零把位置分成三段，看每段里反思词的 PMI。这一步检验 H3，**不需要续写**，最便宜，可以最先出结果。
4. 挑 60 道题做分支续写（阶段 A，见 II.8），检验 H2。

前三步在一次正常的训练里就能完成。导读中的符号都在当页给出直观含义，正式定义见后面的记号页。

第一部分　设定与记号

设定：在线自蒸馏（OPSD）



- x：题目（prompt）。z：特权信息（例如参考解法），只给老师看。
- 学生 π_θ（参数为 θ）采样一个回答 $y = (y_1, \ldots, y_L)$；$h_t = (y_1, \ldots, y_{t-1})$ 是位置 t 之前的前缀。
- 学生：$p_t = \pi_\theta(\cdot \mid x, h_t)$。
  老师：同一个网络，参数为 $\bar{\theta}$，上下文中多了 z：$q_t = \pi_{\bar{\theta}}(\cdot \mid x, z, h_t)$。
- 逐 token 信号 $d_t = \log q_t(y_t) - \log p_t(y_t)$：老师比学生更偏好 y_t 时为正。

普通 OPD 用同样的公式，只是把 $\pi_{\bar{\theta}}(\cdot \mid x, z, h_t)$ 换成一个外部老师模型。精确记号见后面五页。

记号（1/5）：题目、回答、信号

符号	含义
x	题目（prompt）
z	只给老师看的特权信息，例如参考解法或最终答案
$\mathcal{V}$；$a \in \mathcal{V}$	词表；一个 token
G	每道题采样的回答数（组大小）
$y^{(i)} = (y_1^{(i)}, \dots, y_{L_i}^{(i)})$，$i = 1, \dots, G$	对 x 的第 i 个回答；L_i 是它的 token 数
$h_t^{(i)} = (y_1^{(i)}, \dots, y_{t-1}^{(i)})$	回答 i 在位置 t 之前的前缀
$p_{i,t} = \pi_\theta(\cdot \mid x, h_t^{(i)})$，$q_{i,t} = \pi_{\tilde{\theta}}(\cdot \mid x, z, h_t^{(i)})$	学生和老师的下一个 token 分布
$d_{i,t} = \log q_{i,t}(y_t^{(i)}) - \log p_{i,t}(y_t^{(i)})$	逐 token 训练信号
y，L，h_t，p_t，q_t，d_t	只涉及一个回答时，省去下标 i 的同一对象

记号（2/5）：参数与策略

符号	含义
θ	当前学生参数
θ_k；θ_0	第 k 次优化器更新后的参数；初始参数
$\Delta\theta_k = \theta_k - \theta_{k-1}$	第 k 次参数更新量
$\bar{\theta}$	老师参数：等于 θ，或为 θ 的指数滑动平均，或固定不变
π_{old}	生成当前 batch 的策略；它的 log 概率由训练引擎重新计算
T	采样温度
$u_t \in \mathbb{R}^{\lvert\mathcal{V}\rvert}$	位置 t 的学生 logits，已除以 T，因此 $p_t = \text{softmax}(u_t)$，即 $p_t(a) = \exp(u_t(a)) / \sum_{a'} \exp(u_t(a'))$
$e_a \in \mathbb{R}^{\lvert\mathcal{V}\rvert}$	token a 的 one-hot 向量

记号（3/5）：微积分与概率

符号	含义
log, exp	自然对数与指数
$\mathbb{R}$	实数
$\mathbb{E}$, Pr	期望、概率
∇_θ, ∇^2_θ	对 θ 的梯度与 Hessian
$\mathrm{sg}(\cdot)$	停止梯度：数值照常传递，梯度不回传
$D_{\mathrm{KL}}(p\|q) = \sum_a p(a) \log \frac{p(a)}{q(a)}$	KL 散度
$\mathbb{I}[\cdot]$；$\mathrm{sign}(\xi) \in \{-1, 0, 1\}$	条件成立为 1，否则为 0；数 ξ 的符号
$\cos(\mathbf{v}, \mathbf{w}) = \mathbf{v}^\top \mathbf{w} / (\|\mathbf{v}\| \, \|\mathbf{w}\|)$	两个向量的余弦相似度

记号（4/5）：范数与统计

符号	含义
$\|\cdot\|$，$\|\cdot\|_F$，$\|\cdot\|_\infty$；tr	欧氏范数、Frobenius 范数、绝对值最大的元素；矩阵的迹
$\|\cdot\|$	数的绝对值；集合的元素个数；序列的 token 数
mean, std, p_{99}	一组数的均值、标准差、第 99 百分位数
AUROC$(s \to c)$	对分数 s_j 与二值标签 c_j：$\Pr(s_j > s_{j'} \mid c_j = 1, c_{j'} = 0)$，平局计 $\frac{1}{2}$
ρ_{S}	Spearman 相关：秩的 Pearson 相关

记号（5/5）：评测与网络内部

符号	含义
$c_i \in \{0,1\}$； R_i	验证器对 $y^{(i)}$ 的判定（1 为正确）；它的标量奖励，例如 $R_i = c_i$
$\mathrm{ans}(y^{(i)})$； $\mathcal{S}_i \subseteq \{1,\dots,L_i\}$	提取出的最终答案；最终答案 token 所在的位置
$\mathcal{P}$； N	探针集：固定的题目和采样种子；每 N 个训练步重跑一次
$\mathcal{D}_{\mathrm{train}}$， $\mathcal{D}_{\mathrm{held}}$	训练题目；同分布的留出题目
$\mathrm{acc}(\mathcal{D})$	题目集 $\mathcal{D}$ 上的 pass@1：c_i 在题目和样本上的均值（每题 16 个样本时称 avg@16）
$\ell = 1,\dots,N_L$； d_{model}	层编号与层数；隐藏维度
$\phi_t^{(\ell)} \in \mathbb{R}^{d_{\mathrm{model}}}$	第 ℓ 层之后、位置 t 的隐藏状态
Φ_ℓ	一组固定探针 token 的 $\phi_t^{(\ell)}$ 按行排成的矩阵

训练损失及其估计的量

逐 token 损失（策略梯度形式）：

$$\mathcal{L}_t = -\,\mathrm{sg}(d_t)\,\log p_t(y_t)$$

它的期望梯度就是反向 KL 的梯度：

$$\mathbb{E}_{y_t\sim p_t}\big[\nabla_\theta \mathcal{L}_t\big] = \nabla_\theta D_{\mathrm{KL}}(p_t\|q_t)$$

条件：前缀 h_t 视为固定，梯度不流入 $\bar{\theta}$。

证明。 利用 $\sum_a \nabla_\theta p_t(a) = 0$ 和 $\nabla_\theta p_t(a) = p_t(a)\nabla_\theta \log p_t(a)$：

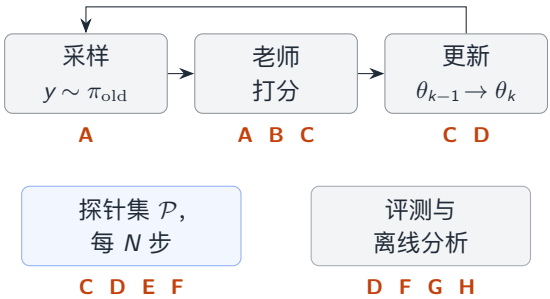
$$\begin{aligned}\nabla_\theta D_{\mathrm{KL}}(p_t\|q_t) &= \sum_{a\in\mathcal{V}} \nabla_\theta p_t(a)\big[\log p_t(a) - \log q_t(a) + 1\big] \\ &= \mathbb{E}_{a\sim p_t}\big[(\log p_t(a) - \log q_t(a))\,\nabla_\theta \log p_t(a)\big].\end{aligned}$$

对采样到的 token $a = y_t$，因子 $\log p_t(y_t) - \log q_t(y_t)$ 等于 $-d_t$，所以期望里的项就是 $-d_t\nabla_\theta \log p_t(y_t) = \nabla_\theta \mathcal{L}_t$。

C 节衡量这个单样本估计离它要估计的量有多远。

成本标签，以及各组统计量所在的环节

免费	已经算好，只需记录
＋ 前向	多一次前向
全词表	需要整个词表（或前若干个 token）上的概率
梯度	需要每个 micro-batch 的梯度，或多一次反向
评测	只在评测时计算
离线	在保存的 checkpoint 或 dump 上计算
＋ 训练	需要额外的训练
续写	从强制前缀开始的学生续写



A. 正确性检查

A. 正确性检查（1/2）：信号算对了吗?

统计量	定义 / 做法	成本	说明什么
空 z 回归	按训练时的方式构造老师输入但去掉 z，并令 $\bar{\theta} = \theta$ 打分。此时 $q_t = p_t$，所以 $\max_t \lvert d_t \rvert$ 应低于噪声底 ν（下一行）。	+ 前向一次	拼接错误、位置错开一位、chat 模板不一致。
噪声底 ν	在理应无关的条件下（换一种 batch 组成；训练引擎 vs. 推理引擎）对同一组 token 打两次分，得到 $q_t^{(1)}, q_t^{(2)}$；在所有打分 token 上取 $\nu = \mathrm{p}_{99} \lvert \log q_t^{(1)}(y_t) - \log q_t^{(2)}(y_t) \rvert$。	+ 前向	$\lvert d_t \rvert < \nu$ 的值与数值噪声无法区分。
Token 对齐	老师输入中对应位置的 token id 等于采样出的 y_t 的比例。	免费	回答被解码后重新分词造成的错位。
老师输入截断	$\lvert x \rvert + \lvert z \rvert + L$ 的分布；超过老师上下文上限 $L_{\max}$ 的比例；z 被截掉一部分的比例。	免费	老师根本没看到完整的 z。

A. 正确性检查（2/2）：数值与记账

统计量	定义 / 做法	成本	说明什么
温度一致性	学生的 log 概率必须使用采样温度 T（verl 在 `dp_actor.py:226` 把 logits 除以 T）。老师的温度要显式选定并记录。	免费	温度不一致会让所有 d_t 整体偏移。
数值异常	NaN/Inf 的个数；$\log p_t(y_t)$ 恰好为 0 或小于 -30 的 token 比例；$\max_t \|u_t\|_\infty$。	免费	bf16 下的溢出与饱和。
老师版本	$\bar{\theta}$ 最近一次从 θ 拷贝时的步数。若老师是 EMA，即 $\bar{\theta} \leftarrow \beta\bar{\theta} + (1-\beta)\theta$，衰减系数 $\beta \in [0,1)$，还要记录 $\|\bar{\theta} - \theta\|/\|\theta\|$。	免费	同步是否按预期进行。
重复行	verl-agent 通过复制行来补齐 batch（`adjust_batch`, `multi_turn_rollout/utils.py:86`）；记录被复制行的比例。	免费	复制行会让部分回答在统计和梯度中权重过高。

行号对应 verl-agent 的 commit 20bd331。

B. 信号落在哪里

B. 信号落在哪里（1/2）：集中程度

单元的信号量：一个 token 为 $|d_{i,t}|$，一个回答为 $\sum_t |d_{i,t}|$，一道题为 $\sum_{i=1}^{G} \sum_t |d_{i,t}|$。下面 $a_1, \ldots, a_n$ 是某一层级上 n 个单元的信号量。

统计量	定义 / 做法	成本	说明什么
Gini 系数	$\mathrm{Gini} = \dfrac{\sum_{j=1}^{n} \sum_{j'=1}^{n} \lvert a_j - a_{j'} \rvert}{2n \sum_{j=1}^{n} a_j}$；0 表示完全均匀，接近 1 表示几乎全部集中在一个单元上。三个层级都要报告。	免费	更新是不是由少数 token、回答或题目驱动的?
Top-1% 占比	$\sum_{j \in \mathcal{T}} a_j / \sum_j a_j$，其中 $\mathcal{T}$ 是 a_j 最大的 1% 单元。	免费	同一个问题，更直观。
低信号题目	每道题的每 token 平均信号 $\bar{a}(x) = \sum_{i,t} \lvert d_{i,t} \rvert / \sum_i L_i$；$\bar{a}(x) < \epsilon_{\mathrm{low}}$ 的题目比例，ϵ_{low} 是选定的阈值，例如 $\epsilon_{\mathrm{low}} = \nu$。	免费	类似 GRPO 里全对或全错的组：生成成本照付，几乎没有梯度。

B. 信号落在哪里（2/2）：逐题动态

对题目 x，k 取遍 x 被采样到的训练步；$\mathrm{acc}_k(x) = \frac{1}{G}\sum_{i=1}^{G} c_i$ 是它在第 k 步的答对比例；$v_k(x) = \mathbb{I}[\mathrm{acc}_k(x) \geq \frac{1}{2}]$ 表示该题算作已解出。

统计量	定义 / 做法	成本	说明什么
逐题学习曲线	第一个满足 $v_k(x) = 1$ 的 k；遗忘事件数 $\sum_k \mathbb{I}[v_{k-1}(x) = 1,\ v_k(x) = 0]$（Toneva et al. 2019）。	免费	哪些题学得快，哪些题学会后又忘了。
信号与提升	跨题目计算 ρ_{S}：一边是累计信号 $\sum_k \bar{a}_k(x)$（$\bar{a}$ 在第 k 步的值），一边是提升 $\mathrm{acc}_{\mathrm{last}}(x) - \mathrm{acc}_{\mathrm{first}}(x)$（最后一次与第一次被采样的步）。	免费 评测	得到更多信号的题目提升更多吗?
有效 token 比例	mask 之后进入损失的 token 数，除以补齐后 batch 张量的全部位置数。	免费	多少计算没有产生梯度。
训练/评测重叠	与某道训练题共享 13-token 片段的评测题比例。	离线	数据污染。

C. 估计量质量

C. 估计量质量（1/2）：单样本 vs. 全分布

单样本估计 （训练中使用）

$$\hat{g} = \sum_{t=1}^{L} \nabla_\theta \mathcal{L}_t = -\sum_{t=1}^{L} d_t \, \nabla_\theta \log p_t(y_t)$$

全分布梯度 （需要 q_t 在整个 $\mathcal{V}$ 上的值）

$$g^{\text{full}} = \sum_{t=1}^{L} \nabla_\theta D_{\mathrm{KL}}(p_t \| q_t)$$

由训练损失那一页的恒等式，$\mathbb{E}[\hat{g} - g^{\text{full}}] = 0$：两者之差是纯噪声。两者都把每个前缀 h_t 视为固定，即忽略 θ 对后续前缀的影响。

统计量	定义 / 做法	成本	说明什么
方向一致性	在 $\mathcal{P}$ 上对每个回答计算 $\cos(\hat{g}, g^{\text{full}})$，再对 batch 平均之后计算一次。只取一层的参数以降低成本。	全词表 梯度	在梯度空间里（而不只是标量上）信号有多吵。
组内梯度离散度	$\hat{g}_i$：由回答 i 得到的估计；$\bar{g} = \frac{1}{G}\sum_i \hat{g}_i$；报告 $\frac{1}{G}\sum_i \|\hat{g}_i - \bar{g}\|^2 / \|\bar{g}\|^2$。	梯度	G 够大吗?

C. 估计量质量（2/2）：与结果的一致性、在线程度

统计量	定义 / 做法	成本	说明什么
密集信号 vs. 结果	$\bar{d}_i = \frac{1}{L_i}\sum_t d_{i,t}$；报告 AUROC$(\bar{d} \to c)$。	免费	逐 token 的判断与最终对错一致吗?
与 GRPO 的符号一致率	$\hat{A}_i = \frac{R_i - \mathrm{mean}(R_1,\ldots,R_G)}{\mathrm{std}(R_1,\ldots,R_G)+10^{-6}}$，$\mathcal{I} = \{i : \hat{A}_i \neq 0\}$，在整个 batch 上汇总：$\sum_{i\in\mathcal{I}}\sum_t \mathbb{I}[\mathrm{sign}\, d_{i,t} = \mathrm{sign}\, \hat{A}_i] / \sum_{i\in\mathcal{I}} L_i$。	免费	混入 RL 时：两种信号推动方向相同的 token 占比。
离策略比率	$r_t = \pi_\theta(y_t \mid x, h_t)/\pi_{\mathrm{old}}(y_t \mid x, h_t)$：它的百分位数，以及一个 mini-batch 中 n 个 token 的归一化有效样本量 $\mathrm{ESS}/n = (\sum_t r_t)^2/(n\sum_t r_t^2) \in (0,1]$。	免费	一步之内偏离 on-policy 的程度。
陈旧度	异步 rollout 时：生成回答所用的参数与正在更新的参数之间相隔的优化器步数。	免费	“on-policy”还成立吗？（AsyncOPD、f-OPD）

D.　梯度与优化器

D. 梯度（1/3）：梯度噪声尺度

g_b：一个累积步内 b 条序列的平均梯度（所有数据并行 rank）；g_B：一个优化器步内全部 B 条序列的平均梯度。

若单条序列梯度的均值为 g、协方差为 Σ，则 $\mathbb{E}\|g_b\|^2 = \|g\|^2 + \mathrm{tr}(\Sigma)/b$，$B$ 同理；联立求解：

$$\widehat{\|g\|^2} = \frac{B\|g_B\|^2 - b\|g_b\|^2}{B-b}, \qquad \widehat{\mathrm{tr}\,\Sigma} = \frac{\|g_b\|^2 - \|g_B\|^2}{1/b - 1/B}, \qquad B_{\mathrm{noise}} = \frac{\widehat{\mathrm{tr}\,\Sigma}}{\widehat{\|g\|^2}}$$

- 分子和分母先分别在若干步上平滑，再相除。
- $B \ll B_{\mathrm{noise}}$：加大 batch 仍能几乎成比例地减少所需步数；$B \gg B_{\mathrm{noise}}$：每步多出来的样本基本浪费（McCandlish et al. 2018）。
- 成本 **梯度**：第一个 micro-batch 之后多做一次梯度范数归约。若损失按 token 平均聚合，按序列的视角只是近似。

D. 梯度（2/3）：步方向与逐 token 推力

统计量	定义 / 做法	成本	说明什么
Micro-batch 一致性	$g_1, \dots, g_M$：一步中 M 个 micro-batch 的梯度，$\bar{g}_M = \frac{1}{M}\sum_m g_m$；报告 $\frac{1}{M}\sum_m \cos(g_m, \bar{g}_M)$。	梯度	步方向稳定吗?
更新持续性	$\cos(\Delta\theta_k, \Delta\theta_{k-1})$，按层计算（保存每层上一步的更新可能放不进显存，可以只选几层）。	免费	在振荡，还是在稳步前进?
逐 token logit 梯度	$\nabla_{u_t}\mathcal{L}_t = -d_t\,(e_{y_t} - p_t)$，因此 $\|\nabla_{u_t}\mathcal{L}_t\| = \|d_t\|\sqrt{1 - 2p_t(y_t) + \sum_a p_t(a)^2}$。按相对位置 t/L 分桶、按 token 类型（数字、公式符号、格式 token、“wait”这类词）分别求和。	全词表（actor 已有 logits）	参数实际被推向哪里：高置信 token（$p_t(y_t) \to 1$）即使 $\|d_t\|$ 很大，梯度也几乎为零。

这里忽略了裁剪和损失的 token 聚合权重，它们只会缩放某些行或把它们置零。

D. 梯度（3/3）：损失地形与可塑性

统计量	定义 / 做法	成本	说明什么
锐度	$\lambda_{\max}$：$\nabla^2_\theta \mathcal{L}_{\mathcal{P}}$ 的最大特征值，其中 $\mathcal{L}_{\mathcal{P}}$ 是 $\mathcal{P}$ 上所有 token 的 $\mathcal{L}_t$ 之和；用 Hessian–向量积做幂迭代（PyHessian）。	离线	训练是否在走向更尖锐的区域?
特征有效秩	$\sigma_1, \ldots, \sigma_r$：$\Phi_\ell$ 的奇异值；$\bar{\sigma}_j = \sigma_j / \sum_{j'} \sigma_{j'}$；$\mathrm{erank}(\Phi_\ell) = \exp\big(-\sum_j \bar{\sigma}_j \log \bar{\sigma}_j\big)$（Roy & Vetterli 2007）。	+ 前向	特征坍缩；已知与可塑性丧失相关。
权重范数增长	$\|\theta_k\| / \|\theta_0\|$，按层计算。	免费	权重增长也伴随可塑性丧失（Dohare et al. 2024）。
休眠单元	MLP 单元（down-projection 的输入）中，在所有探针 token 上绝对激活都低于阈值 δ 的比例。	+ 前向	不再起作用的单元。

E. 校准与置信度

E. 校准（1/2）：置信度分数及其评价方式

反向 KL 是 mode-seeking 的（Gu et al. 2024），所以蒸馏后的学生容易过度自信。每个回答有两种置信度分数：

$$\kappa_i^{\text{tok}} = \exp\Big(\frac{1}{|\mathcal{S}_i|}\sum_{t\in\mathcal{S}_i}\log p_{i,t}\big(y_t^{(i)}\big)\Big), \qquad \kappa_i^{\text{vote}} = \frac{1}{G}\sum_{j=1}^{G}\mathbb{I}\big[\,\text{ans}(y^{(j)}) = \text{ans}(y^{(i)})\big]$$

κ_i^{tok}：答案 token 概率的几何平均。κ_i^{vote}：组内最终答案与它相同的回答占比。

对 n 个回答，分数为 κ_i（任一种），判定为 c_i：

$$\text{ECE} = \sum_{m=1}^{N_{\text{bin}}}\frac{|\mathcal{B}_m|}{n}\Big|\operatorname*{mean}_{i\in\mathcal{B}_m} c_i - \operatorname*{mean}_{i\in\mathcal{B}_m}\kappa_i\Big|$$

把 $[0,1]$ 等分成 N_{bin} 个区间；$\mathcal{B}_m$ 是 κ_i 落在第 m 个区间的回答（Guo et al. 2017）。

$$\text{Brier} = \frac{1}{n}\sum_{i=1}^{n}(\kappa_i - c_i)^2$$

区分度：AUROC($\kappa \to c$)。

三者成本：**免费**

E. 校准（2/2）：过度自信与不确定性

统计量	定义 / 做法	成本	说明什么
错误答案的置信度	mean$\{\kappa_i : c_i = 0\}$。	免费	过度自信是否在加剧?
Self-certainty	$\frac{1}{L_i}\sum_t D_{\mathrm{KL}}(U \Vert p_{i,t})$，$U$ 是 $\mathcal{V}$ 上的均匀分布（Kang et al. 2025）。	全词表	从整个分布读出的总体置信水平。
语义熵	按最终答案把 G 个回答聚类；簇 $\mathcal{C}$ 的占比为 $\hat{p}_{\mathcal{C}} = \lvert\mathcal{C}\rvert/G$；$\mathrm{SE}(x) = -\sum_{\mathcal{C}} \hat{p}_{\mathcal{C}} \log \hat{p}_{\mathcal{C}}$。报告 AUROC$(-\mathrm{SE} \to c^{\mathrm{maj}})$，最大簇正确时 $c^{\mathrm{maj}}(x) = 1$。	免费	不确定性还能标出错误吗?（简化自 Kuhn et al. 2023，原文按蕴含关系聚类。）
含糊表达频率	每 1000 token 中“I'm not sure”“might be”等短语的出现次数。	免费	模型是否不再表达怀疑?

F. 表示与机制

F. 表示（1/2）：网络变了多少、变在哪里

两个矩阵 X 与 Y 行数都为 n（同样的 token，同样的顺序），列已中心化，它们的线性 CKA（中心化核对齐，Kornblith et al. 2019）为：

$$\mathrm{CKA}(X, Y) = \frac{\|Y^\top X\|_F^2}{\|X^\top X\|_F \, \|Y^\top Y\|_F} \in [0, 1]$$

统计量	定义 / 做法	成本	说明什么
逐层漂移	对每一层 ℓ，在同一组探针 token 上计算 $\mathrm{CKA}(X, Y)$，X、Y 分别是 θ_0 和 θ_k 下的 Φ_ℓ。	**+ 前向**	变化发生在浅层还是深层?
师生对齐	行为回答位置 t_s。X：给定 (x, h_t) 时学生第 ℓ 层的状态；Y：给定 (x, z, h_t) 时老师第 ℓ 层的状态。画出它随训练的变化。	**+ 前向**（在老师前向上加 hook）	学生的内部状态是否在向 z 在老师中诱导出的状态靠拢?

F. 表示（2/2）：机制

统计量	定义 / 做法	成本	说明什么
对 z 的注意力	$\mathcal{Z}$：老师输入中 z 的位置；$\mathcal{R}$：回答的位置；$\omega_{t,s}^{(\ell,j)}$：第 ℓ 层第 j 个头中从位置 t 到 s 的注意力权重；每层 N_h 个头。$\alpha_\ell = \frac{1}{\lvert\mathcal{R}\rvert N_h} \sum_{t\in\mathcal{R}} \sum_{j=1}^{N_h} \sum_{s\in\mathcal{Z}} \omega_{t,s}^{(\ell,j)}$。	+ 前向	老师读了多少 z；若 $\bar{\theta} = \theta$，它在训练中是否变化。
Logit lens 稳定层	W_U：unembedding 矩阵；Norm：最后的归一化层。$\ell_t^\star$：使得对所有 $\ell' \geq \ell$ 都有 $\arg\max_a [W_U \,\mathrm{Norm}(\phi_t^{(\ell')})]_a = \arg\max_a p_t(a)$ 的最小 ℓ。	+ 前向	训练是否让决策提前到更浅的层?
正确性探针	从 $\phi_{L_j}^{(\ell)}$（回答的最后一个 token）到 c_i 的逻辑回归；每层 ℓ 的留出 AUROC。	离线	模型“知道”自己错了吗?
激活幅度	$\max_{t,\ell} \lVert\phi_t^{(\ell)}\rVert_\infty$ 和 $\max_t \lVert u_t\rVert_\infty$。	+ 前向	bf16 风险（massive activations，Sun et al. 2024）。

FlashAttention 内核不返回注意力权重，所以计算 α_ℓ 要用 eager attention。

G.　泛化、遗忘与鲁棒性

G. 泛化（1/2）：还有什么跟着变了

统计量	定义 / 做法	成本	说明什么
通用能力回退	训练前后在 MMLU-Pro、GPQA、IFEval、HumanEval（或你关心的评测集）上对比。	评测	提升是否以牺牲其他能力为代价?
记忆差距	$\mathrm{acc}(\mathcal{D}_{\mathrm{train}}) - \mathrm{acc}(\mathcal{D}_{\mathrm{held}})$。	评测	学的是方法，还是记住了题目?
跨领域迁移	在数学上训练，在代码、科学、逻辑上评测。	评测	提升能迁移多远?
改写鲁棒性	把每道评测题写成 J 种模板或改写；acc_j：模板 j 下的准确率；报告 $\mathrm{std}(\mathrm{acc}_1, \ldots, \mathrm{acc}_J)$。	评测	是否过拟合了训练模板?

G. 泛化（2/2）：更难的题、事实性、不完美的参考

统计量	定义 / 做法	成本	说明什么
难度外推	在比训练集更难的题（更高难度等级、竞赛题）上的准确率。	评测	提升能延伸到更难的题吗?
事实性	在 SimpleQA 类数据集上：作答中答错的比例。	评测	过度自信是否蔓延到事实类问题?
带噪 z 的鲁棒性	训练时把比例为 η 的 z 换成错误参考；画出最终 $\mathrm{acc}(\mathcal{D}_{\mathrm{held}})$ 随 η 的变化。	+ 训练	对参考质量的敏感度；真实数据集里本来就有错误解法。

H. 实验严谨性

H. 严谨性（1/2）：核心数字的不确定性

- **种子。**每个设置至少 3 个训练种子；报告均值和 95% 置信区间（Agarwal et al. 2021）。
- **按题目 bootstrap。**有放回地重采样题目，重算指标，取第 2.5 和第 97.5 百分位数。在 30 题的测试集上一道题就是 $1/30 \approx 3.3$ 个点，所以至少要用 avg@16。
- **配对比较：**方法 A 与 B 在同一组题目上比较。

$$\chi^2 = \frac{(n_{01} - n_{10})^2}{n_{01} + n_{10}}$$

n_{10}：A 解出而 B 没解出的题数；n_{01}：反之。与自由度为 1 的 χ^2 分布比较（McNemar 1947）。

用 avg@16 时每题得分不是二值的，此时改用对逐题差值的配对 bootstrap。

H. 严谨性（2/2）：噪声底、算力对齐、checkpoint 选择

- **探针统计量的噪声底。**在同一个 checkpoint 上用不同采样种子跑两次 $\mathcal{P}$，得到某个统计量的两个值 $\hat{m}^{(1)}, \hat{m}^{(2)}$。小于 $|\hat{m}^{(1)} - \hat{m}^{(2)}|$ 的变化不应解读。
- **按算力对齐的横轴。**除了训练步数，还要以累计生成 token 数、老师打分 token 数和 GPU 小时为横轴作图。OPSD 每步多一次老师前向，按步数作图会美化它。
- **固定的 checkpoint 选择规则。**报告最后一个 checkpoint，以及按事先固定的规则在验证集上选出的最佳 checkpoint。绝不在测试集上挑选。

汇总

执行计划：三档

档位	时机 / 数据	统计量
1	每步，完整训练 batch	A：token 对齐、截断、温度、数值异常、老师版本、重复行。B：除训练/评测重叠外全部。C：密集信号 vs. 结果、符号一致率、离策略比率、陈旧度。D：噪声尺度、micro-batch 一致性、更新持续性、逐 token logit 梯度、权重范数。E：置信度分数、ECE、Brier、错误答案置信度、语义熵、含糊表达。
2	每 N 步，探针集 $\mathcal{P}$	C：方向一致性、组内梯度离散度。D：有效秩、休眠单元。E：self-certainty。F：逐层漂移、师生对齐、对 z 的注意力、logit lens、激活幅度。
3	checkpoint 和 dump	A：空 z 回归和噪声底（做一次）。B：训练/评测重叠。D：锐度。F：正确性探针。G 和 H。

第 1 档的组统计量在 driver 上计算

逐题统计量和按对错分组的统计量需要整个 batch，但在 verl 中每个数据并行 worker 只看到一个分片。

每个探针点要 dump 什么

保存原始量后，上面所有统计量都能离线计算，以后新增统计量也不必重新训练。

逐 token

token id、位置 t、回答编号 i
$\log p_{i,t}(y_t^{(i)})$， $\log q_{i,t}(y_t^{(i)})$， $\|\nabla_{u_t}\mathcal{L}_t\|$
$p_{i,t}$ 和 $q_{i,t}$ 下概率最高的 20 个 token 及其概率

逐回答

c_i， L_i， $\mathrm{ans}(y^{(i)})$， κ_i^{tok}， κ_i^{vote}

选定的层、抽样的位置

$\phi_t^{(\ell)}$ 用 bf16 存：每 token 每层 $2d_{\mathrm{model}}$ 字节。

存储量估算

两个 top-20 列表，4 字节 id + 2 字节概率：每 token $2 \times 20 \times 6 = 240$ 字节。

隐藏状态，$d_{\mathrm{model}} = 1536$（Qwen2.5-1.5B）：每 token 每层约 3 KB，10^6 个 token 每层约 3 GB。需要对位置抽样。

第一部分的优先级

1. **A 全部做。**几乎免费；只要有一项不通过，其他统计量都没有意义。
2. **H 中的多种子和按算力对齐的横轴。**审稿人通常两者都会要求。
3. **G 的通用能力回退，以及 E 的错误答案置信度。**遗忘和过度自信是蒸馏最常见的两个副作用。
4. **B、C、E 中标为 免费 的行**放进第 1 档；**D 和 F** 放进第 2 档，在探针集上计算。

第二部分

针对一个假设的统计量：

特权信息 PMI 与前缀兼容度（idea 003）

II.0　记号与假设

第二部分记号（1/3）：分解信号

不带 z 的老师网络，使用与学生相同的 prompt 模板：$q_t^0 = \pi_{\bar{\theta}}(\cdot \mid x, h_t)$。

$$d_t = \underbrace{\log q_t(y_t) - \log q_t^0(y_t)}_{\mathrm{PMI}_t} + \underbrace{\log q_t^0(y_t) - \log p_t(y_t)}_{\Delta_t^{\mathrm{snap}}}$$

- PMI_t（得名于点互信息）：看到 z 让老师对 y_t 的 log 概率提高了多少。
- Δ_t^{snap}（快照差）：老师参数与学生参数之间的差异。
- 若在 rollout 时令 $\bar{\theta} = \theta$，则一步中的第一个 mini-batch 上 $\Delta_t^{\mathrm{snap}} = 0$，此时 $d_t = \mathrm{PMI}_t$，PMI_t 不需要额外计算。之后的 mini-batch 上 $\Delta_t^{\mathrm{snap}} = -\log r_t$（$r_t$ 见 C 节）。

第二部分记号（2/3）：前缀兼容度

对任意策略 π，前缀的概率为 $\pi(h_t \mid x) = \prod_{u=1}^{t-1} \pi(y_u \mid x, h_u)$，上下文中带 z 时同理。由链式法则：

$$S_t = \sum_{u=1}^{t-1} \mathrm{PMI}_u = \log \frac{\pi_{\bar{\theta}}(h_t \mid x, z)}{\pi_{\bar{\theta}}(h_t \mid x)}, \qquad S_1 = 0$$

- $S_t > 0$：看到 z 时这段前缀更可能出现；它沿着 z 的路线走。
- $S_t < 0$：前缀已经离开这条路线，例如换了方法或出了错。
- $S_t \approx 0$：还没有证据，常见于回答的开头。

第二部分记号（3/3）：其他符号

符号	含义
$\mathcal{H}(p) = -\sum_a p(a) \log p(a)$	$\mathcal{V}$ 上的分布 p 的熵
p_1，p_5，p_{10}，p_{50}，$\cdots$	百分位数，定义方式同 p_{99}
Var, Cov, corr	在 token 上计算的方差、协方差、Pearson 相关
$T_m(p)$；$\mathrm{rank}_p(a)$	概率最高的 m 个 token；比 a 概率更高的 token 数加一
$\hat{y}_t = \arg\max_a q_t(a)$；$\mathrm{eos}$	老师在 t 处的 top-1 token；序列结束 token
$\mathcal{W}$	反思词：wait、but、hmm、let me check、actually、alternatively
z^+；z^-	正确参考（$z^+ = z$）；同一模板下的错误参考
$\pi(y \mid x)$，$\pi(y \mid x, z)$	$\prod_{t=1}^{L} \pi(y_t \mid x, h_t)$：整段回答的概率（带 z 时同理）

第二部分：待检验的假设（均未检验）

- **H1（可推得性）。**学生自己能推出 z 时（例如图像裁剪），OPSD 有益。在长推理上，学生推不出 z 时（例如参考解法），OPSD 有害，且 z 携带的信息越多，危害越大。
- **H2（看兼容度，不看位置）。**老师在 t 处的指导是否有用，取决于 S_t，而不是相对位置 t/L。
- **H3（反思 token）。**$\mathcal{W}$ 中的 token 在 $S_t \geq 0$ 处 PMI_t 为负，在 $S_t < 0$ 处 PMI_t 接近 0 或为正。

假设	关键统计量
H1	按 z 的类型分的 PMI_t（II.4）；反思词频率（II.6）；准确率随生成预算的变化（II.1）
H2	可靠性 AUROC、增量价值、按位置分层的 AUROC、帮助度与兼容度的关系（II.5）
H3	反思词的 PMI_t，按 S_t 的符号和回答对错拆分（II.4）

II.1　训练健康度与任务指标

II.1 训练健康度（1/2）：训练稳定吗?

统计量	定义 / 做法	成本	说明什么
损失与梯度范数	损失；裁剪前的梯度范数；因梯度出现非有限值而跳过的步数比例。	**免费**	训练稳定吗?
裁剪比例、近似 KL	ϵ_{clip}：PPO 的裁剪范围。$r_t \notin [1-\epsilon_{\text{clip}}, 1+\epsilon_{\text{clip}}]$ 的 token 比例；$\log \pi_{\text{old}}(y_t \mid x, h_t) - \log \pi_\theta(y_t \mid x, h_t)$ 的均值（verl：`pg_clipfrac`、`ppo_kl`）。	**免费**	一步把策略移动了多远。
学生熵	$\mathcal{H}(p_t)$：均值、p_{10}、p_{50}、p_{90}，以及 $\mathcal{H}(p_t) < 0.01$ 的 token 比例。	**免费**	熵坍缩了吗?

II.1 训练健康度（2/2）：输出与引擎

统计量	定义 / 做法	成本	说明什么
长度与截断	L：均值、p_{50}、p_{90}、最大值；在 eos 之前被生成上限截断的回答比例。	**免费**	OPSD 让回答变长还是变短？预算够吗？
退化输出	出现重复循环、格式错误（例如没有 `\boxed{}`）或语言混杂的回答比例。	**免费**	输出在退化吗？
引擎不一致	π_{inf}：推理引擎在采样时给出的概率。$\lvert\log \pi_{\mathrm{inf}}(y_t \mid x, h_t) - \log \pi_{\mathrm{old}}(y_t \mid x, h_t)\rvert$ 的最大值和 p_{99}（`ray_trainer.py:1153`）。	**免费**	隐藏的离策略程度。

II.1 任务指标（1/2）：准确率与探索

统计量	定义 / 做法	成本	说明什么
在线准确率	训练 batch 上 c_i 的均值；即使 c_i 不进入损失也要记录。	免费	学生在进步吗?
pass@K 曲线	K：尝试次数。某题有 n_{smp} 个样本，其中 n_{cor} 个正确：$\mathrm{pass@}K = 1 - \binom{n_{\mathrm{smp}}-n_{\mathrm{cor}}}{K} \Big/ \binom{n_{\mathrm{smp}}}{K}$（Chen et al. 2021），对题目取平均，$K = 1, 2, 4, \ldots, 64$。	评测	蒸馏是否缩小了学生能找到的解的范围?
maj@K	K 个样本中出现最多的答案为正确答案的题目比例。	评测	投票后的准确率。
探索差距	pass@64 减去 pass@1。	评测	多样性是否被压缩?
难度分桶	$\mathrm{acc}_{\theta_0}(x)$：$\theta_0$ 下 x 的样本答对比例。分桶 $\{0\}$、$(0, \frac{1}{2}]$、$(\frac{1}{2}, 1)$、$\{1\}$；每桶准确率随训练的变化。	评测	哪些题提升，哪些题退步?

II.1 任务指标（2/2）：退步、上限、预算

统计量	定义 / 做法	成本	说明什么
逐题翻转	至少一半样本正确的题算作已解出。在 θ_0 与最终 checkpoint 之间统计：未解出 $\to$ 解出、解出 $\to$ 未解出、始终未解出、始终解出的题数。	评测	是否有题目变差?
模仿差距	老师在上下文中带 z 作答（从 $\pi_{\tilde{\theta}}(\cdot \mid x, z)$ 采样）的 acc 减去学生的 acc。	评测	老师最多能把学生拉高多少?
准确率 vs. 预算	若干生成上限下的 acc($\mathcal{D}_{\text{held}}$)。	评测	预算越长是否越差? (Rethinking OPSD 报告过)
按对错分的长度	分别计算 $c_i = 1$ 和 $c_i = 0$ 的回答的平均 L_i。	免费	长度与正确性的关系。

领域外准确率见第一部分 G 节。

II.2 信号 d_t

II.2 信号 d_t（1/2）：分布

统计量	定义 / 做法	成本	说明什么
形状	均值 μ_d、标准差 σ_d、p_1、p_5、p_{50}、p_{95}、p_{99}、最小值、最大值、峰度 $\mathbb{E}[(d_t-\mu_d)^4]/\sigma_d^4$。	免费	信号是重尾的吗?
符号与尾部	$\Pr(d_t>0)$、$\Pr(d_t<-5)$、$\Pr(\lvert d_t\rvert>2)$。	免费	主要在推高 token，还是在压低?
近零占比	$\Pr(\lvert d_t\rvert<\epsilon_{\text{low}})$，$\epsilon_{\text{low}}$ 见 B 节。	免费	多少 token 几乎没有得到监督?
回答层面	$\sum_t d_{i,t}$、$\bar{d}_i$，以及回答内 $d_{i,t}$ 的方差。	免费	回答之间差别有多大。

II.2 信号 d_t（2/2）：落在哪里

统计量	定义 / 做法	成本	说明什么
位置分桶	把 t/L 等分成 10 个桶；每桶 d_t 的均值和方差。	免费	位置效应；PW-OPSD 与 LGR 的结论相反。
按对错	分别计算 $c_i = 1$ 和 $c_i = 0$ 的回答上 $d_{i,t}$ 的均值。	免费	老师是否还在改写已经正确的回答?
结束符信号	每个位置的 $\log q_t(\mathrm{eos}) - \log p_t(\mathrm{eos})$。	全词表	长度变化是不是因为老师在推动更早或更晚结束?
Token 类别	$\mathcal{W}$ 中的词、数字、公式符号、格式 token、答案 token（$t \in \mathcal{S}_i$）各自的平均 d_t。	免费	哪类 token 承载了信号?

II.3　师生分布差距

II.3 分布差距（1/2）：p_t 与 q_t 相差多远?

统计量	定义 / 做法	成本	说明什么
逐 token 散度	$D_{\mathrm{KL}}(p_t\|q_t)$、$D_{\mathrm{KL}}(q_t\|p_t)$； $\mathrm{JSD} = \frac{1}{2}D_{\mathrm{KL}}(p_t\|m_t) + \frac{1}{2}D_{\mathrm{KL}}(q_t\|m_t)$，其中 $m_t = \frac{1}{2}(p_t + q_t)$；$\mathrm{TV} = \frac{1}{2}\sum_a \lvert p_t(a) - q_t(a)\rvert$。	全词表	差距有多大；在正向和反向 KL 之间切换影响有多大。
Top-1 一致率	$\Pr\left[\arg\max_a p_t(a) = \hat{y}_t\right]$。	全词表	两者想要的下一个 token 相同吗?
老师眼中的样本	$q_t(y_t)$ 和 $\mathrm{rank}_{q_t}(y_t)$。	免费 全词表	学生是否经常写出老师认为不太可能的 token?
Top-10 重合度	$\lvert T_{10}(p_t) \cap T_{10}(q_t)\rvert / \lvert T_{10}(p_t) \cup T_{10}(q_t)\rvert$。	全词表	两者的候选集有多相似?

II.3 分布差距（2/2）：熵与近似误差

统计量	定义 / 做法	成本	说明什么
老师熵	$\mathcal{H}(q_t)$，以及 $(\mathcal{H}(p_t), \mathcal{H}(q_t))$ 的二维直方图。	全词表	哪里老师很确定而学生在犹豫（SEAD 就按这种方式划分 token）。
Top-m 质量	截断损失只保留 m 个 token 时的 $\sum_{a \in T_m(q_t)} q_t(a)$。	全词表	用 top-m 近似 KL 时忽略掉的概率质量。
单样本 vs. 精确值	$-d_t$ 是 $D_{\mathrm{KL}}(p_t \Vert q_t)$ 的无偏估计；报告 $\mathrm{corr}(-d_t, D_{\mathrm{KL}}(p_t \Vert q_t))$。	全词表	单样本信号的噪声（vOPD）；梯度层面的版本见 C 节。

II.4　PMI 分解与前缀兼容度

II.4 恒等式检查：最先做

在约 20 个回答上先做以下检查，再相信本部分的任何统计量：

1. **求和恒等式。**检查
$$\sum_{t=1}^{L} \mathrm{PMI}_t = \log \pi_{\bar{\theta}}(y \mid x, z) - \log \pi_{\bar{\theta}}(y \mid x)$$
其中整段回答的 log 概率单独计算；每 token 的误差应小于 10^{-3}。
2. **token 相同。**回答的 token id 在两种 prompt 模板（带 z 与不带 z）中完全相同。
3. **记录的信号。**$\bar{\theta}$ 与 θ 同步时，训练中记录的 d_t 等于离线重算的 PMI_t。

成本：＋ **前向** 一次。这些检查是对 A 节通用检查的补充。

II.4 逐 token 特征（idea 003，F0–F7）

编号	特征	定义	成本
F0	相对位置（基线）	$(t-0.5)/L$	免费
F1	老师熵（基线）	把 q_t 限制在 $T_{16}(q_t)$ 上并重新归一化后的 $\mathcal{H}$（PW-OPSD）	全词表
F2	PMI	PMI_t	免费 / + 前向
F3	累计 PMI	S_t	同 F2
F4	平均累计 PMI	$S_t/(t-1)$，$t \geq 2$	同 F2
F5	局部特权散度	在 $T_{64}(q_t) \cup T_{64}(q_t^0)$ 上、其余 token 合并为一个桶时的 $D_{\mathrm{KL}}(q_t \| q_t^0)$	全词表
F6	候选 PMI	对 $a \in T_3(q_t)$ 计算 $\log q_t(a) - \log q_t^0(a)$：取最大值和均值	全词表
F7	对比累计 PMI	$\sum_{u=1}^{t-1} \left[\log \pi_{\bar\theta}(y_u \mid x, z^+, h_u) - \log \pi_{\bar\theta}(y_u \mid x, z^-, h_u)\right]$	+ 前向

$\bar\theta = \theta$ 时 F2–F4 为 免费。F7 把 z 的内容与参考解法的风格分开。II.5 检验 F0–F7 作为可靠性预测因子的效果。

II.4 训练中的 PMI 统计量（1/2）

本页和下一页中，$\bar{\theta} = \theta$ 时成本为 **免费**，否则为 **+ 前向**。

统计量	定义 / 做法	成本	说明什么
PMI 分布	PMI_t 的分布：整体、按位置桶、按 token 类别。	**免费** **+ 前向**	z 偏好或惩罚哪些 token?
方差分解	$\mathrm{Var}(d_t) =$ $\mathrm{Var}(\mathrm{PMI}_t) + \mathrm{Var}(\Delta_t^{\mathrm{snap}}) + 2\,\mathrm{Cov}(\mathrm{PMI}_t, \Delta_t^{\mathrm{snap}})$。	**+ 前向**	老师固定或用 EMA 时，d_t 主要由哪一部分驱动?
兼容度剖面	S_t 的百分位数随 t 的变化；$S_t < 0$ 的 token 比例；正确与错误回答上 S_{L+1} 的分布。	**免费** **+ 前向**	前缀是否沿着 z 的路线走?
兼容度 vs. 信号	$\mathrm{corr}(S_t, \lvert d_t \rvert)$。	**免费** **+ 前向**	在不兼容的前缀上，信号是否更极端?

II.4 训练中的 PMI 统计量（2/2）

统计量	定义 / 做法	成本	说明什么
反思词 PMI (H3)	$y_t \in \mathcal{W}$ 处的平均 PMI_t：正确 vs. 错误回答；错误回答内部，$S_t \geq 0$ vs. $S_t < 0$。对照组：位置匹配、不在 $\mathcal{W}$ 中的 token。	**免费** **+ 前向**	压制是否取决于前缀状态?
对比 PMI	$\log \pi_{\bar{\theta}}(y_t \mid x, z^+, h_t) - \log \pi_{\bar{\theta}}(y_t \mid x, z^-, h_t)$。	**+ 前向**	去掉参考风格之后的内容效应（RLCSD）。
按 z 的类型分	z 分别为仅最终答案、完整解法、提示时的同样统计量。	每种类型 **+ 前向**	信息越多，危害越大?（H1）
序列层面	$\bar{\theta} = \theta$ 时：$\mathbb{E}_{y \sim \pi_\theta(\cdot \mid x)}[S_{L+1}] = -D_{\mathrm{KL}}\big(\pi_\theta(\cdot \mid x) \,\|\, \pi_\theta(\cdot \mid x, z)\big)$。	**免费**	训练是否在把 $\pi_\theta(\cdot \mid x)$ 拉向 $\pi_\theta(\cdot \mid x, z)$?

II.5　前缀可靠性：分支续写

II.5 分支标签：什么时候跟着老师走有帮助?

主干（spine）：一个固定的学生回答（正确：$c = 1$；错误：$c = 0$）。$h \oplus a$：前缀 h 后接 token a。$\hat{V}(h)$：从 h 出发、不带 z 的 n_{roll} 次学生续写中正确的比例。

正确主干（PW-OPSD 协议）

每题最多取 F1 最高的 5 个位置；对每个 $a \in T_3(q_t)$ 强制续写；$n_{\text{roll}} = 6$。

多解（diversity）：至少两个候选达到 $\hat{V}(h_t \oplus a) \geq 0.75$。

真不确定（real-uncertain）：所有候选及其均值都低于 0.40。

其余为**灰区（gray）**，不计入 AUROC。

错误主干（帮助度标签）

每条主干取 5 个位置，在 t/L 上均匀分布；$n_{\text{roll}} = 8$：

$$\Delta_t = \hat{V}(h_t \oplus \hat{y}_t) - \hat{V}(h_t \oplus y_t)$$

$\Delta_t > 0$：老师的 top-1 token 对不带 z 的学生有帮助。若 $\hat{y}_t = y_t$，令 $\Delta_t = 0$，并报告这种情况的频率。

成本 **续写**：正确主干需要题数 $\times 5 \times 3 \times 6$ 次续写，错误主干需要题数 $\times 5 \times 2 \times 8$ 次。

II.5 分支标签上的统计量

统计量	定义 / 做法	成本	说明什么
可靠性 AUROC	F0–F7 各自区分真不确定与多解的 AUROC，先减去每题的平均分；按题目 bootstrap 的 95% CI（2000 次重采样）。	续写	兼容度能否胜过位置?
增量价值	5 折逻辑回归，按题目划分折：F0 加一个特征的留出 AUROC，减去只用 F0 的留出 AUROC，附 bootstrap CI。	离线	位置之外的信息。
按位置分层的 AUROC	在 t/L 的每个三分段内，F3 和 F5 的 AUROC。	离线	把兼容度与“兼容度和位置的相关性”分开。
帮助度 vs. 兼容度	$\rho_{\mathrm{S}}(\Delta_t, S_t)$；给定 t/L 的偏相关（两者分别对 t/L 回归后残差的相关）；$S_t \geq 0$ 与 $S_t < 0$ 时的平均 Δ_t。	续写	偏离 z 的路线是否使指导失真（LGR)?
救回与背书	救回：在 $\hat{V}(h_t) \leq 0.1$ 处 $\hat{V}(h_t \oplus \hat{y}_t)$ 的均值。错误步：$\hat{V}(h_{t+1}) \leq \hat{V}(h_t) - 0.3$；错误步中 $\mathrm{PMI}_t > 0$ 的比例。	续写	老师能救回正在失败的学生吗？会为错误背书吗?

II.5 预先登记的判据（来自 idea 003）

结果	结论
F3 或 F5 的 AUROC $\geq$ F0 的，且增量的 CI 不含 0	支持 H2：兼容度提供了位置之外的信息
增量的 CI 含 0，但在位置三分段内 F3/F5 的 AUROC > 0.6	兼容度与位置大部分重合，H2 只部分成立
位置三分段内 F3/F5 的 AUROC ≈ 0.5	H2 不成立，位置效应另有原因
给定 t/L 时 Δ_t 与 S_t 的偏相关明显为正	支持“偏离 z 的路线导致指导失真”
Δ_t 与 S_t 无关	LGR 的衰减不能用兼容度解释
$S_t < 0$ 段上反思词的 PMI 明显更高	支持 H3：值得尝试按前缀状态屏蔽
F7 优于 F3	风格是噪声来源，对比基线是必要的

正负结果都要保留。单个模型、单组题目上的结果不能当作普遍结论。

II.6　推理行为与多样性

II.6 推理行为与多样性（1/2）

统计量	定义 / 做法	成本	说明什么
反思词频率	每 1000 token 中 $\mathcal{W}$ 里的词出现的次数。	**免费**	分叉抑制（fork suppression）：学生是否不再自我检查?
自我纠正	中途改变所给答案的回答比例；其中改成正确答案和改成错误答案的比例。	**免费**	纠错是否被抑制?
同题多样性	G 个回答中：不同最终答案的个数；self-BLEU（Zhu et al. 2018）；两两嵌入距离的均值；两个回答第一次出现不同 token 的平均位置。	**免费** / **离线**	回答是否坍缩成同一种形式?

II.6 推理行为与多样性（2/2）

统计量	定义 / 做法	成本	说明什么
解法路线	用 LLM 评判按方法给 G 个回答聚类；簇的个数。	评测	是否只剩下参考解法那一条路线?
答案泄漏	y 与 z 的重合：共享的 n-gram、ROUGE-L、最长公共子串；最终答案在 y 中首次出现的相对位置。	免费	是在推理还是在背诵? 答案出现得越来越早是警告信号。
风格漂移	在初始模型下的困惑度 $\exp\big(-\frac{1}{L}\sum_t \log \pi_{\theta_0}(y_t \mid x, h_t)\big)$。	+ 前向	写作风格离初始模型有多远?

这里“n-gram”中的 n 是片段长度，例如 4。含糊表达频率和语义熵见 E 节。

II.7　参数动态与成本

II.7 参数动态

统计量	定义 / 做法	成本	说明什么
相对初始模型的漂移	在探针 token 上取平均的 $D_{\mathrm{KL}}\big(\pi_\theta(\cdot \mid x, h_t) \| \pi_{\theta_0}(\cdot \mid x, h_t)\big)$。	+ 前向 全词表	模型移动了多远?
老师漂移	$q_t^{(k)}$：使用第 k 步参数的老师分布。在 $\mathcal{P}$ 上计算 $D_{\mathrm{KL}}(q_t^{(k)} \| q_t^{(k-N)})$。	+ 前向 全词表	$\bar{\theta}$ 跟随 θ 时，目标移动得有多快?
蒸馏梯度 vs. RL 梯度	g_{D}、g_{RL}：混合损失中蒸馏项和 RL 项的梯度。$\|g_{\mathrm{D}}\|/\|g_{\mathrm{RL}}\|$、$\cos(g_{\mathrm{D}}, g_{\mathrm{RL}})$、余弦为负的层所占比例。	梯度	两个目标在互相打架吗？(Dr.OPD)
逐层更新幅度	$\theta^{(\ell)}$：第 ℓ 层的参数；$\|\Delta\theta_k^{(\ell)}\|/\|\theta_k^{(\ell)}\|$。	免费	哪些层在变?
更新结构	对每个权重矩阵 W，取它在一个训练窗口内的变化 ΔW：erank(ΔW)（D 节），以及 $\|\Delta W\|$ 低于阈值 δ_W 的元素比例。	离线	更新是低秩的还是稀疏的?

II.7 成本

统计量	定义 / 做法	成本	说明什么
Token 计数	每步：生成的 token 数、老师打分的 token 数、为得到 q_t^0 额外打分的 token 数。	**免费**	每一部分的开销。
时间	老师打分占每步时间的比例；每步的墙钟时间；达到目标准确率所需的 GPU 小时。	**免费**	时间花在哪里。
截断监督	若损失只保留部分 token，并按包含概率的倒数重新加权 (例如 STOPD)：保留比例和最大权重。	**免费**	重新加权稳定吗?

II.8　切片、执行计划与分阶段

II.8 切片与执行计划

几乎每个统计量都按三种方式切片：按判定 c_i；按初始难度桶（II.1）；按 t/L 的位置桶（II.2）。很多效应只在切片内部才看得到，例如老师还在改写已经正确的回答的风格。

档位	时机 / 数据	第二部分的统计量
1	每步，完整训练 batch	II.1 训练健康度、在线准确率、按对错分的长度；II.2；II.4 在 $\bar{\theta} = \theta$ 时：S_t 的百分位数、$S_t < 0$ 的比例、反思词 PMI；II.6 反思词频率、自我纠正、答案泄漏；II.7 逐层更新幅度和成本。
2	每 N 步，探针集 $\mathcal{P}$	II.3；II.4 中需要 q_t^0 或 z^- 的统计量；II.6 多样性和风格漂移；II.7 相对初始模型的漂移和老师漂移。
3	离线	II.1 评测指标；II.4 恒等式检查；II.5 分支标签及其统计量；II.7 更新结构。

II.8 需要追加 dump 的字段，以及分阶段计划

额外字段（在第一部分的 dump 之上）

逐 token：$\log q_t^0(y_t)$、$\mathcal{H}(p_t)$、$\mathcal{H}(q_t)$，各用 4 字节浮点数，外加 1 字节标记 $y_t \in \mathcal{W}$：共 13 字节。

逐回答：z 的类型；最终答案首次出现的相对位置。

逐分支：位置 t、强制的 token、n_{roll}、$\hat{V}$。

分阶段（idea 003）

A. 60 道题：恒等式检查和正确主干标签；在比较新特征之前，先确认位置 AUROC 与 PW-OPSD 接近。

B. 题目数量要足以得到至少 40 个真不确定位置（保留初始通过率在 $[0.2, 0.8]$ 的题）；做全部分支统计量和 H3。

C. 在正在进行的 OPSD 或 STOPD 训练中加入第 1 档的兼容度统计量。

附录

缩写与术语（1/2）

OPD	在线蒸馏（on-policy distillation）：学生采样，老师给每个 token 打分
OPSD	在线自蒸馏：老师就是看到 z 的学生自己的网络
GRPO	组相对策略优化
RL	强化学习
EMA	指数滑动平均
ESS	有效样本量
AUROC	ROC 曲线下面积
ECE	期望校准误差
CKA	中心化核对齐
MLP	Transformer 层中的前馈模块
micro-batch	每次反向传播处理的 batch 切片；梯度在切片间累加
rollout	用当前策略生成回答

checkpoint; dump	训练中保存的参数；存到磁盘上的原始中间量
bf16	16 位浮点格式（bfloat16）
NaN/Inf	非数值 / 无穷大的浮点值
FSDP	全分片数据并行（训练引擎）
vLLM	用于 rollout 的推理引擎
verl(-agent)	RL 训练框架（agent 版本）
pass@1	单个样本答对的概率
avg@16	用每题 16 个样本估计的 pass@1
FlashAttention	融合的注意力内核；与普通（“eager”）注意力不同，它不返回注意力权重

缩写与术语（2/2）

PMI	点互信息；这里指第二部分的对数比 PMI_t
JSD; TV	Jensen–Shannon 散度；全变差距离
PPO	近端策略优化（裁剪范围 ϵ_{clip} 的来源）
LLM	大语言模型
CI	置信区间
ROUGE-L	基于最长公共子序列的重合度
self-BLEU	每个回答相对于同组其他回答的 BLEU（*n*-gram 精度）的均值
H1–H3; F0–F7	假设（II.0）和逐 token 特征（II.4）
主干、多解、真不确定、灰区	分支标签的术语（spine、diversity、real-uncertain、gray），定义见 II.5
方法名	PW-OPSD、LGR、SEAD、vOPD、RLCSD、Dr.OPD、STOPD、Rethinking OPSD、AsyncOPD、f-OPD：见参考文献

符号索引（1/3）：第一部分的记号页与设定页

符号	所在页
x, z, θ, $\bar{\theta}$	设定
$\mathcal{V}$, a, G	记号 1
$y^{(i)}$, L_i, $h_t^{(i)}$	记号 1
$p_{i,t}$, $q_{i,t}$, $d_{i,t}$	记号 1
y, L, h_t, p_t, q_t, d_t	设定，记号 1
θ, θ_k, θ_0	记号 2
$\Delta\theta_k$, $\bar{\theta}$	记号 2
π_θ, $\pi_{\bar{\theta}}$	设定，记号 1
π_{old}	记号 2
T, u_t, e_a	记号 2
$\mathcal{L}_t$	训练损失

符号	所在页
log, exp, $\mathbb{R}$	记号 3
$\mathbb{E}$, Pr	记号 3
∇_θ, ∇^2_θ, sg	记号 3
D_{KL}, $\mathbb{I}$, sign	记号 3
cos	记号 3
$\|\cdot\|$, $\|\cdot\|_F$, $\|\cdot\|_\infty$	记号 4
tr, $\lvert\cdot\rvert$	记号 4
mean, std, p_{99}	记号 4
AUROC, ρ_{S}	记号 4

符号	所在页
c_i, R_i	记号 5
ans, $\mathcal{S}_i$	记号 5
$\mathcal{P}$, N	记号 5
$\mathcal{D}_{\mathrm{train}}$, $\mathcal{D}_{\mathrm{held}}$	记号 5
$\mathrm{acc}(\mathcal{D})$	记号 5
ℓ, N_L, d_{model}	记号 5
$\phi_t^{(\ell)}$, Φ_ℓ	记号 5

导读中的符号在当页给出直观含义，正式定义以本索引所列页为准。

符号索引（2/3）：第一部分，在首次使用处定义

符号	所在页
ν, $q_t^{(1)}$, $q_t^{(2)}$	A (1/2)
$L_{\max}$	A (1/2)
β	A (2/2)
a_j, n, Gini, $\mathcal{T}$	B (1/2)
$\bar{\mathrm{a}}(x)$, ϵ_{low}	B (1/2)
$\mathrm{acc}_k(x)$, $v_k(x)$	B (2/2)
$\bar{\mathrm{a}}_k(x)$	B (2/2)
$\hat{g}$, g^{full}	C (1/2)
$\hat{g}_i$, $\bar{g}$	C (1/2)
$\bar{d}_i$, $\hat{A}_i$, $\mathcal{I}$	C (2/2)
r_t, ESS	C (2/2)

符号	所在页
g, Σ, b, B	D (1/3)
g_b, g_B, B_{noise}	D (1/3)
M, g_m, $\bar{g}_M$	D (2/3)
$\lambda_{\max}$, $\mathcal{L}_{\mathcal{P}}$	D (3/3)
σ_j, r, $\bar{\sigma}_j$	D (3/3)
erank, δ	D (3/3)
κ_i^{tok}, κ_i^{vote}	E (1/2)
ECE, N_{bin}, $\mathcal{B}_m$	E (1/2)
Brier	E (1/2)
U, $\mathcal{C}$, $\hat{p}_{\mathcal{C}}$	E (2/2)
SE, c^{maj}	E (2/2)

符号	所在页
CKA, X, Y	F (1/2)
$\mathcal{Z}$, $\mathcal{R}$, N_h	F (2/2)
$\omega_{t,s}^{(\ell,j)}$, α_ℓ	F (2/2)
W_U, Norm, $\ell_t^\star$	F (2/2)
J, acc_j	G (1/2)
η	G (2/2)
n_{01}, n_{10}, χ^2	H (1/2)
$\hat{m}^{(1)}$, $\hat{m}^{(2)}$	H (2/2)

求和下标（j、j'、m、s、t、ℓ'）由所在的求和或集合绑定。计数 n 在用到它的每一页（B、C、E、F）上重新定义。

符号索引（3/3）：第二部分

符号	所在页
q_t^0, PMI_t	II 记号 1
Δ_t^{snap}	II 记号 1
S_t	II 记号 2
$\pi(h_t \mid x)$	II 记号 2
$\mathcal{H}$, $\mathrm{p}_1, \mathrm{p}_5, \ldots$	II 记号 3
Var, Cov, corr	II 记号 3
T_m, rank_p	II 记号 3
$\hat{y}_t$, eos, $\mathcal{W}$	II 记号 3
z^+, z^-, $\pi(y \mid x)$	II 记号 3

符号	所在页
ϵ_{clip}, π_{inf}	II.1 健康度
K, n_{smp}, n_{cor}	II.1 任务（1/2）
$\mathsf{acc}_{\theta_0}(x)$	II.1 任务（1/2）
μ_d, σ_d	II.2（1/2）
m_t, JSD, TV	II.3（1/2）
F0–F7	II.4 特征

符号	所在页
$\oplus$, $\hat{V}$, n_{roll}	II.5 标签
Δ_t	II.5 标签
$q_t^{(k)}$	II.7 动态
g_{D}, g_{RL}	II.7 动态
$\theta^{(\ell)}$, W, ΔW, δ_W	II.7 动态

参考文献 i

- K. Lu and Thinking Machines Lab. On-Policy Distillation. *Connectionism* blog, 2025.
- R. Agarwal et al. On-Policy Distillation of Language Models: Learning from Self-Generated Mistakes (GKD). ICLR 2024.
- Y. Gu et al. MiniLLM: Knowledge Distillation of Large Language Models. ICLR 2024.
- Self-Distilled Reasoner: On-Policy Self-Distillation for Large Language Models. arXiv:2601.18734, 2026.
- AsyncOPD: How Stale Can On-Policy Distillation Be? arXiv:2606.24143, 2026.
- f-OPD: Stabilizing Long-Horizon On-Policy Distillation with Freshness-Aware Control. arXiv:2605.17862, 2026.
- When Are Teacher Tokens Reliable? Position-Weighted On-Policy Self-Distillation for Reasoning (PW-OPSD). arXiv:2605.21606, 2026.
- Rethinking On-Policy Self-Distillation for Thinking Models. arXiv:2607.05184, 2026.

参考文献 ii

- RLCSD: Reinforcement Learning with Contrastive On-Policy Self-Distillation. arXiv:2606.11709, 2026.
- SEAD: Competence-Aware On-Policy Distillation via Entropy-Guided Supervision. arXiv:2606.28562, 2026.
- KL for a KL: On-Policy Distillation with Control Variate Baseline (vOPD). arXiv:2605.07865, 2026.
- Your Teacher Can't Help You Here: Combating Supervision Fidelity Decay in On-Policy Distillation (LGR). arXiv:2605.30833, 2026.
- Dr. OPD: Learning What to Follow for Optimal On-Policy Distillation of Large Language Models. arXiv:2609.38025, 2026.
- Does On-Policy Distillation Need to Complete Every Rollout? (STOPD). Code: github.com/YouAreSpecialToMe/STOPD, 2026.

参考文献 iii

- J. Schulman et al. Proximal Policy Optimization Algorithms. arXiv:1707.06347, 2017.
- M. Chen et al. Evaluating Large Language Models Trained on Code (pass@K estimator). arXiv:2107.03374, 2021.
- Y. Zhu et al. Texygen: A Benchmarking Platform for Text Generation Models (self-BLEU). SIGIR 2018.
- C.-Y. Lin. ROUGE: A Package for Automatic Evaluation of Summaries. ACL Workshop, 2004.
- Z. Shao et al. DeepSeekMath (GRPO). arXiv:2402.03300, 2024.
- M. Toneva et al. An Empirical Study of Example Forgetting during Deep Neural Network Learning. ICLR 2019.
- S. McCandlish, J. Kaplan, D. Amodei et al. An Empirical Model of Large-Batch Training. arXiv:1812.06162, 2018.
- Z. Yao et al. PyHessian: Neural Networks Through the Lens of the Hessian. IEEE BigData 2020.

参考文献 iv

- O. Roy, M. Vetterli. The Effective Rank: A Measure of Effective Dimensionality. EUSIPCO 2007.
- S. Dohare et al. Loss of Plasticity in Deep Continual Learning. *Nature*, 2024.
- C. Guo et al. On Calibration of Modern Neural Networks. ICML 2017.
- Z. Kang, X. Zhao, D. Song. Scalable Best-of-N Selection for Large Language Models via Self-Certainty. arXiv:2502.18581, 2025.
- L. Kuhn, Y. Gal, S. Farquhar. Semantic Uncertainty: Linguistic Invariances for Uncertainty Estimation in Natural Language Generation. ICLR 2023.
- S. Kornblith et al. Similarity of Neural Network Representations Revisited. ICML 2019.
- nostalgebraist. Interpreting GPT: the Logit Lens. LessWrong, 2020.
- M. Sun, X. Chen, J. Z. Kolter, Z. Liu. Massive Activations in Large Language Models. COLM 2024.

参考文献 v

- R. Agarwal et al. Deep Reinforcement Learning at the Edge of the Statistical Precipice. NeurIPS 2021.
- Q. McNemar. Note on the Sampling Error of the Difference between Correlated Proportions or Percentages. *Psychometrika*, 1947.
- Benchmarks: MMLU-Pro (Wang et al. 2024), GPQA (Rein et al. 2023), IFEval (Zhou et al. 2023), HumanEval (Chen et al. 2021), SimpleQA (Wei et al. 2024).