SFT · PPO · GRPO · OPD · OPSD

先区分轨迹来自谁、监督来自谁，再比较 loss；箭头表示组件变换，不表示唯一训练顺序。

SFT
参考文本 → 明确目标

$$\mathcal{L}_{\mathrm{SFT}} = -\sum_{t} \log \pi_\theta(y_t^* \mid x, y_{<t}^*)$$

强项：稳定、适合冷启动
问题：参考前缀与推理前缀不同

PPO
学生尝试 → reward + critic

$$\widehat{A}_t = \sum_{l \geq 0} (\gamma\lambda)^l \delta_{t+l}$$

强项：任务收益、可 bootstrap
问题：critic 偏差与探索成本

PPO → GRPO：将 value baseline 换成同题组统计

GRPO
同题多条回答互相比较

$$\widehat{A}_i = \frac{R_i - \bar{R}}{\sigma_R + \epsilon}$$

强项：省 learned critic
问题：全同奖励为零、信用粗

OPD
学生前缀 → teacher 分布

$$\mathcal{L}_{\mathrm{OPD}} = \mathbb{E}_{y \sim \pi_\theta} \sum_{t} D(p_t, q_t)$$

强项：局部反馈密集
问题：teacher 偏好未必有益

OPSD
同模型 + 额外信息作 teacher

$$q_t = \pi_{\bar{\theta}}(\cdot \mid x, z, y_{<t})$$

强项：利用自身信息优势
问题：z 缺失、风格和探索错配

OPD → OPSD：让同模型 teacher 获得额外参考信息

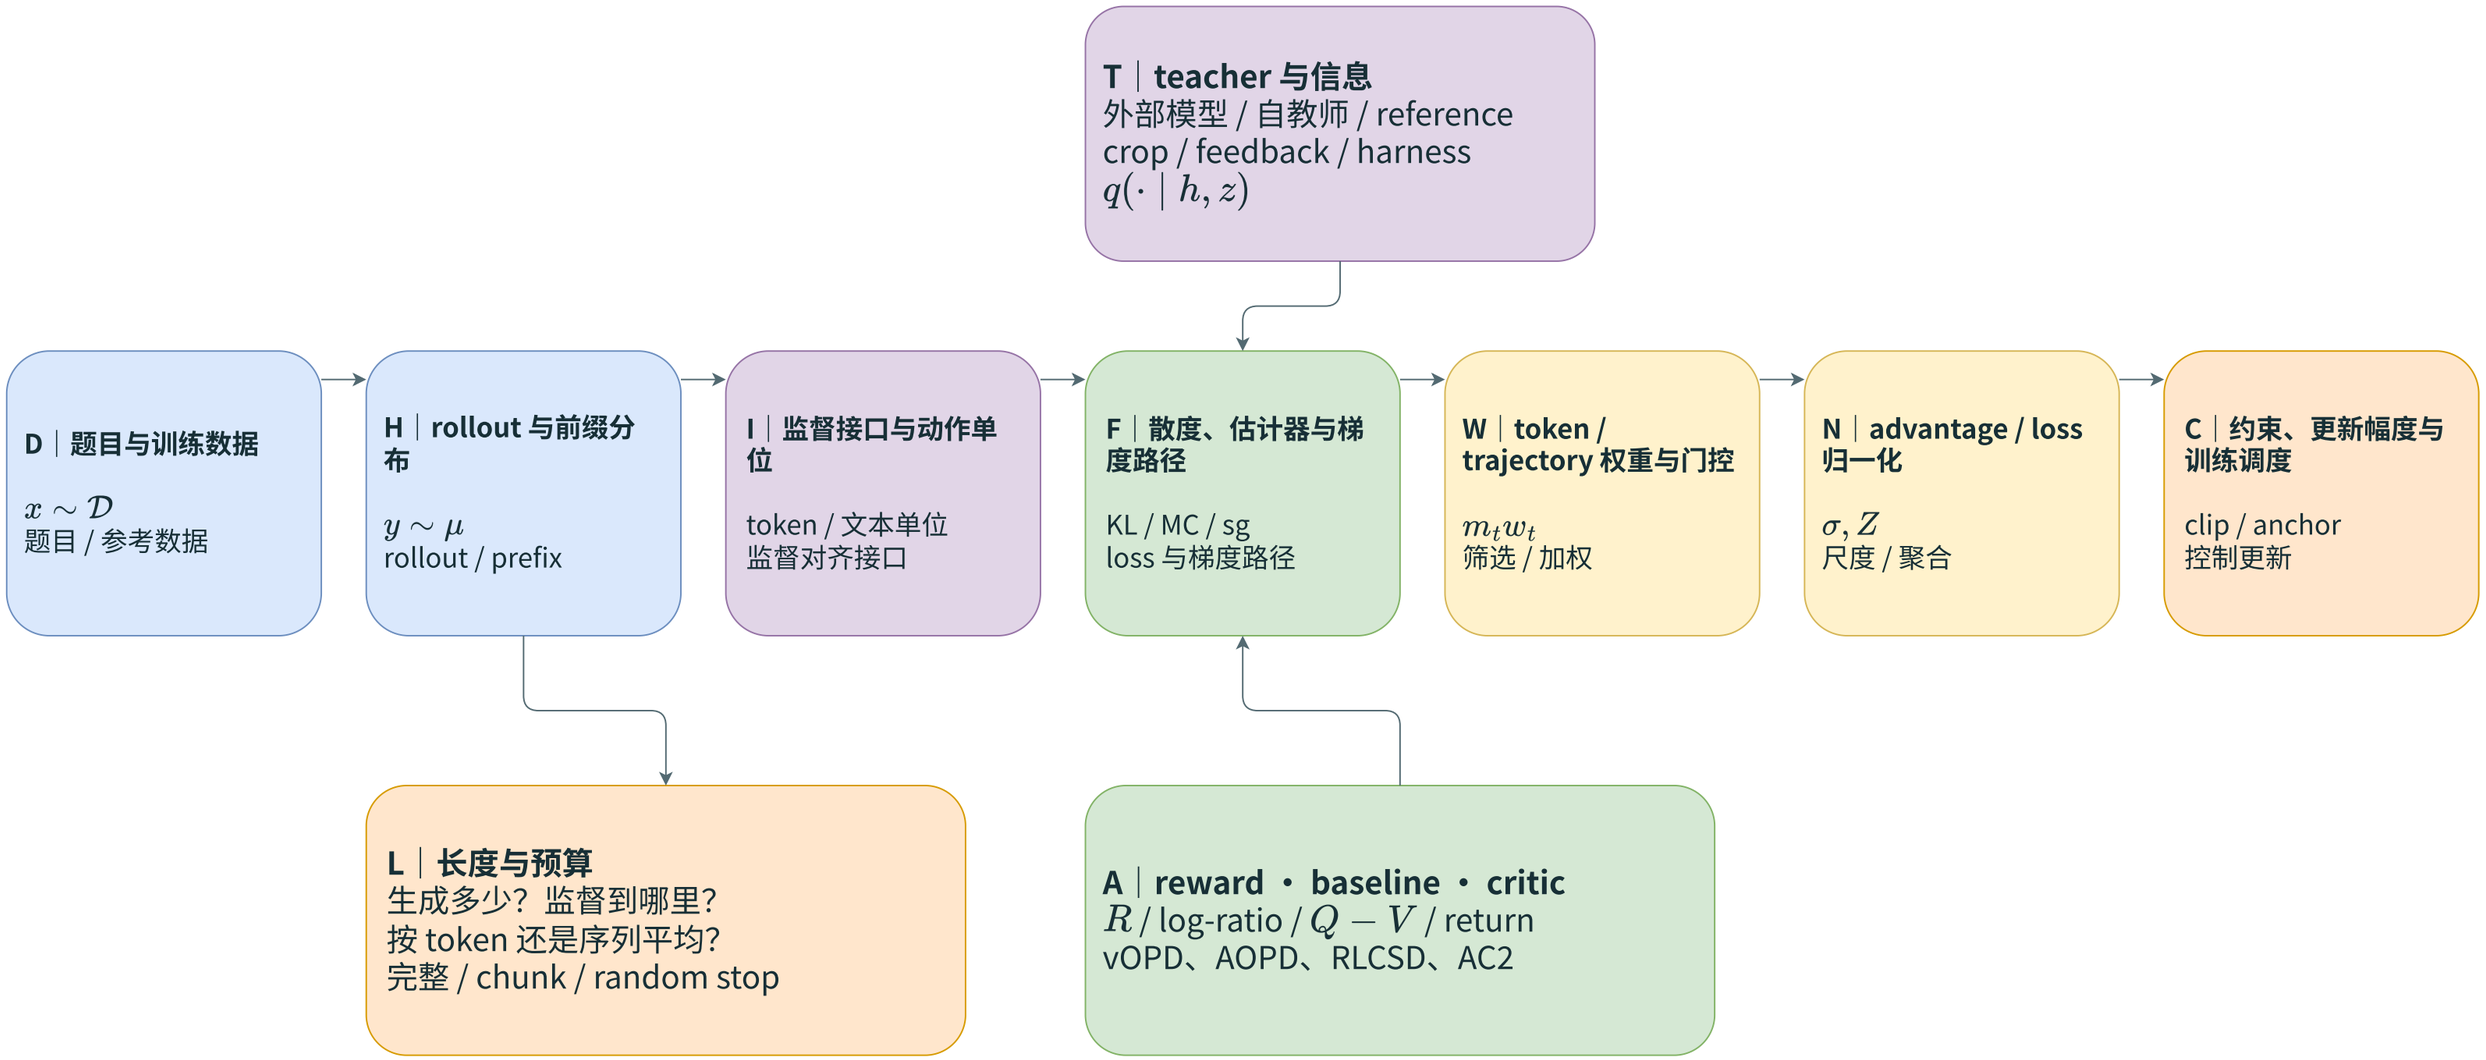
一个共同框架
题目 → 采样状态 → 构造信号 → 权重 / 归一化 → 更新

改动可以很小，但“目标变了”与“只换估计器”必须区分。

数据 / 轨迹 | teacher / 接口 | 监督信号 / 估计 | 权重 / 归一化 | 更新 / 长度

训练循环的十个可修改位置

每篇论文可以同时修改多个位置；长度 L 横跨采样 H、信号 A、权重 W 和归一化 N。



示例：DF-OPD 改 D；CorrGRPO 改 N；AC2 改 H/A/L；STOPD 改 H/W/N/L；TOP-D 改 T/F/A/N/C/L。

数据 / 轨迹 | teacher / 接口 | 监督信号 / 估计 | 权重 / 归一化 | 更新 / 长度

论文在哪里动手：按组件查，而非按新名字记

每张卡是一个可继续展开的组件分支；一篇论文可出现多次。细节与关键公式见认知卡片 / 离线浏览器。

D｜题目与训练数据

SEAD · ReDraft
DF-OPD

H｜rollout 与前缀分布

f-OPD · AsyncOPD
Noisy Expert / NAIL · TrOPD
D-OPSD / Few-step Image Diffusion · ReDraft
Draft-OPD · AC2
STOPD

T｜teacher 来源与额外信息

Many Faces of OPD · TOP-D
LGR / Supervision Fidelity Decay · CoPD / Co-Evolving Policy Distillation
VPD / Variational Policy Distillation · Rethinking OPSD
OPHSD / Harness Self-Distillation · d-OPSD / Self Future dLLMs
PRISM / Black-box Multimodal RL · VC-OPD
Vision-OPD · VA-OPD / Visual Advantage
GUI-SD · D-OPSD / Few-step Image Diffusion
OPSD / Self-Distilled Reasoner · PIVOT
RLCSD · DuoOPD

I｜监督接口与动作单位

SimCT · d-OPSD / Self Future dLLMs
GUI-SD · D-OPSD / Few-step Image Diffusion
Draft-OPD

F｜散度、估计器与梯度路径

AsyncOPD · Noisy Expert / NAIL
vOPD / KL Control Variate · REOPOLD / Relaxed OPD
SEAD · Many Faces of OPD
TOP-D · TrOPD
PRISM / Black-box Multimodal RL · ReDraft
Draft-OPD · AOPD
PowerOPD

A｜奖励、return、baseline 与 critic

vOPD / KL Control Variate · TOP-D
LGR / Supervision Fidelity Decay · VPD / Variational Policy Distillation
RWOPD / NL-to-SVA · PIVOT
Dr.OPD · RLCSD
AOPD · AC2
PowerOPD · DuoOPD

W｜token / trajectory 权重与门控

f-OPD · Rock Tokens
REOPOLD / Relaxed OPD · SEAD
PW-OPSD / Teacher Token Reliability · LGR / Supervision Fidelity Decay
TrOPD · Rethinking OPSD
RWOPD / NL-to-SVA · VC-OPD
VA-OPD / Visual Advantage · GUI-SD
PIVOT · Dr.OPD
RLCSD · Draft-OPD
AOPD · STOPD
DN-MOPD · DIAL-OPD
PowerOPD · DuoOPD

N｜advantage / loss 归一化

REOPOLD / Relaxed OPD · TOP-D
VC-OPD · VA-OPD / Visual Advantage
CorrGRPO · AOPD
AC2 · STOPD
DN-MOPD · DIAL-OPD
DuoOPD

C｜约束、更新幅度与训练调度

f-OPD · AsyncOPD
EffOPD / Learning to Foresee · REOPOLD / Relaxed OPD
SEAD · Many Faces of OPD
TOP-D · TrOPD
CoPD / Co-Evolving Policy Distillation · VPD / Variational Policy Distillation
PRISM / Black-box Multimodal RL · Dr.OPD
AC2

L｜token length、截断与预算

TOP-D · PW-OPSD / Teacher Token Reliability
LGR / Supervision Fidelity Decay · Rethinking OPSD
Draft-OPD · AC2
STOPD · DIAL-OPD

正文待核对（只保留题名指向）
Better Rollouts · CoTrek · Fewer Tokens / Fewer Layers · Early Risk Hindsight
REOPOLD 依据同方法 arXiv 版本，原 OpenReview 版细节未逐字核对。

数据 / 轨迹 | teacher / 接口 | 监督信号 / 估计 | 权重 / 归一化 | 更新 / 长度

不要把所有 token length 改动混为一谈

生成截断、loss mask、长度分母、未来 return 和位置权重，作用位置不同。

GRPO outcome
每条序列所有 token 共用 $\widehat{A}_i$；通常需要完整终局结果



完整回答 → terminal reward

AC2 chunk
ready 时不生成后半段；用 $V(sc_i)$ 构造组内优势



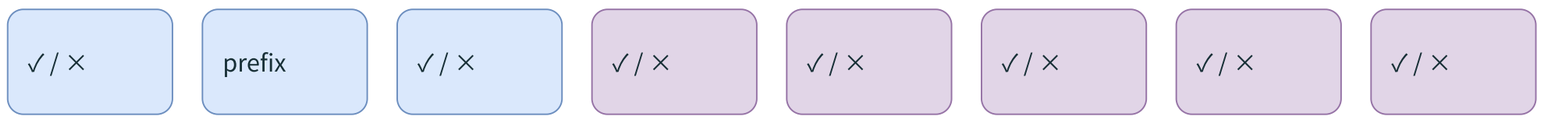
replay prefix → 新 chunk → critic V

STOPD block
不预测未生成未来；IPW 补偿后段 token 的覆盖差异



随机停止 → 局部 teacher → $1/p_t$

Draft-OPD block
block 用于投机验证与接受长度；不是 value chunk



draft 提议 → target 验证 → anchor replay

loss 长度聚合：三种不同权重
序列平均：$\frac{1}{B}\sum_i \frac{1}{T_i}\sum_t \ell_{it}$
token 平均：$\frac{\sum_{i,t}\ell_{it}}{\sum_i T_i}$
固定分母：$\frac{\sum_{i,t}\ell_{it}}{BL}$

还要分开记录
训练预算 ≠ 测试预算；已生成后 mask ≠ 提前停止
TOP-D：即时信号 + 平均未来 return
PW-OPSD：相对位置权重；VLM：输入 vision token 数

都能少做完整 rollout，但学习信号来自不同地方

AC2 用 learned critic 估计未生成未来；STOPD 对已定义的局部监督做随机抽样与 IPW 补偿。

AC2 · 恢复同一个 replay prefix s

复用起点，之后的新 chunk 由当前 actor 生成

AC2 · 分叉生成多个新 chunk c_i

不是从历史轨迹随意截几段直接拟合

AC2 · 检查 critic 是否 ready

未 ready / audit → 完整终局 R_i
ready 且截断 → $V(sc_i)$

AC2 · 构造 chunk advantage，再 PPO 更新

$\widehat{A}_i = v_i - \frac{1}{G}\sum_j v_j$
主实验不除 σ；chunk 内共享 credit

STOPD · 生成前随机抽停止 block

$A \sim \mathrm{Unif}\{0, \ldots, L-1\}$
停止点与轨迹独立

STOPD · 仅生成到 stop 或自然 EOS

实际生成 $M = \min(T, S)$
teacher 对保留前缀提供局部反馈

STOPD · 按保留概率的倒数加权

$p_t = \frac{L - K\lfloor (t-1)/K \rfloor}{L}$
晚位置少保留，但权重 $1/p_t$ 更大

STOPD · 以 lagged token count 归一化

$\mathbb{E}_S[\widehat{G}] = G, \quad \mathbb{E}_S[\hat{g}] = \frac{N}{C} g^{\mathrm{v}}$
梯度和无偏，归一化仍有尺度差异

重要条件
AC2：critic 要校验，仍保留真实评分通路。
STOPD：局部 loss 不能依赖被删掉的未来；IPW 不能直接恢复需要终局 reward 的 GRPO。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

f-OPD

认知：旧 rollout 可以复用，但应按新鲜程度决定它还值得信任多少。

方法：根据策略漂移、teacher 上下文漂移和更新滞后降低旧样本权重，并加入 rollout 锚定及缓冲区刷新。

$$f_i = \frac{\exp[-\alpha\sqrt{D_i^{\text{roll}}} - \beta\sqrt{D_i^{\text{sup}}}]}{1+\tau_i}$$
$$w_i = [f_i - \xi]_+$$

改动：H · W · C
公式：原文核心式
边界：新鲜度是偏差代理，不是精确因果可靠性。

AsyncOPD

认知：异步训练能提高吞吐，但 loss 方向和打分缓存决定旧数据是否还能用。

方法：比较 FKL/RKL 的陈旧性，在 learner 端重算当前 student 信号，并用多样本 MC 降低单采样方差。

$$\hat{g}_M = \frac{1}{M}\sum_{m=1}^{M} g(a_m;\pi_\theta,T), \quad a_m \sim \mu$$

改动：H · F · C
公式：结构示意
边界：μ 是真实提议分布；需要论文对应的重要性校正，不能简单重采样就宣称无偏。

Noisy Expert / NAIL

认知：当专家带噪声时，学生访问自己的状态再问专家，可能比离线模仿更有样本效率。

方法：建立 noisy-expert 模型，推导离线与在线 imitation 的复杂度分离，并提出鲁棒在线 NAIL 变体。

$$\pi_\eta^* = (1-\eta)\pi^* + \eta\nu$$

改动：H · F
公式：原文设置式
边界：多项式或 horizon-free 结论有噪声与 domination 条件；不是所有 SFT 都指数困难。

Rock Tokens

认知：高 loss 不一定意味着值得学；持续难以纠正的风格残差可能消耗大量梯度。

方法：识别持续高 loss token 及关联窗口，降低其权重；Rock-Freeze 将这些区域权重设为零。

$$w_t = \begin{cases} 0, & y_t \in \mathcal{R} \text{ or } t \in \mathcal{W}_R \\ 1, & \text{otherwise} \end{cases}$$

改动：W
公式：原文特例
边界：需要持续性与干预诊断；不能把所有高 loss token 都删掉。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

vOPD / KL Control Variate

认知：用一个与当前动作无关的 baseline，可让 OPD 梯度更稳定而保持其期望。

方法：以负 reverse KL 作为局部 log-ratio 奖励的期望 baseline，detach 后从单采样信号中减去。

$$a_t = \log \frac{T(y_t|h_t)}{S(y_t|h_t)} + D_{\mathrm{KL}}(S\|T)$$

改动：A · F
公式：原文核心式
边界：这是局部蒸馏奖励 baseline，不能替代任务终局价值；降方差有分析条件。

EffOPD / Learning to Foresee

认知：如果早期更新方向已经接近最终方向，可以沿当前方向多走一点来加速。

方法：分析模块分配与低秩更新方向，采用自适应 extrapolation 步长。

$$\theta_{k+1} = \theta_k + \alpha_k \Delta\theta_k$$

改动：C
公式：结构示意
边界：外推倍数必须控制；稳定方向的经验现象不是全局收敛保证。

Better Rollouts

认知：关注点是收集什么 rollout，而不只是在已有 rollout 上换 loss。

方法：本地尚无 PDF，具体采样机制待核对。

关键公式待正文核对

改动：H
公式：待核对
边界：不根据题名补写具体算法。

REOPOLD / Relaxed OPD

认知：强烈负监督应适度，低信息 token 不必占据同样的学习预算。

方法：限制负 log-ratio 尾部，先按奖励门控、后按学生 entropy 选 token，分阶段探索与精炼。

$$\hat{r}_t = \max\left(\mathrm{sg}(r_t), \frac{\log \lambda}{1-\lambda}\right)$$

改动：F · W · C · N
公式：arXiv 相关版本原文式
边界：依据 arXiv:2603.11137；与原列表及 workshop 版本的逐字对应尚未核实。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

SEAD

认知：监督要匹配学生当前能力：太难的前缀和已掌握的 token 都可能浪费训练。

方法：联合 teacher/student entropy 分区选择 loss 或跳过，随阶段从 FKL 过渡到 RKL，配合由易到难课程。

$$\ell_{t,k} = m_{t,k}\Big[\alpha_k D_{\mathrm{FKL}} + (1-\alpha_k) D_{\mathrm{RKL}}\Big]$$

改动：D · F · W · C
公式：结构示意
边界：该式抽象三项组件；实际分区和调度以原文为准，不能只独立套其中一项。

SimCT

认知：两模型 tokenizer 不同时，先找到可比较的文本单位，比直接比较 token id 更重要。

方法：除共享 token 外，纳入双方都能表达的短 multi-token continuations，扩展监督接口。

$$\mathcal{U} = \mathcal{V}_{\text{shared}} \cup \mathcal{C}_{\text{jointly tokenizable}}$$

改动：I
公式：结构示意
边界：扩大接口不等于强行对齐不同 token id；序列概率需按各自 tokenizer 计算。

Many Faces of OPD

认知：teacher 强不够，还要检查前缀兼容性、TopK 梯度与特权信息是否能迁移。

方法：诊断三类失败，比较 stop-gradient TopK、RLVR teacher 与 SFT 稳定化。

$$g = \sum_{a \in \mathcal{K}} \mathrm{sg}\left[S(a) \log \frac{T(a)}{S(a)}\right] \nabla \log S(a)$$

改动：T · F · C
公式：结构示意
边界：TopK surrogate 与完整 KL 不能无条件等同；这是诊断加稳定化研究。

TOP-D

认知：teacher 太远时先构造较近的目标，再用受控更新逐步接近它。

方法：teacher/student 概率插值，使用平滑 log-ratio、长度归一化未来 return、token 组标准化与 PPO 式内部迭代。

$$T_\alpha = \alpha T + (1-\alpha) S$$
$$\tilde{r}_t = \log\left(\alpha \frac{T(y_t)}{S(y_t)} + 1 - \alpha\right)$$

改动：T · F · A · N · C · L
公式：原文核心式
边界：不只做插值；概率空间插值与 log 概率缩放不同。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

PW-OPSD / Teacher Token Reliability

认知：高 entropy 既可能是坏分支，也可能是多种好解法；可靠性不能只看 entropy。

方法：先做分支可行性诊断，再在训练中按相对位置给递增权重，弱化早期监督。

$$L = \frac{\sum_t w(t/|y|)\ell_t}{\sum_t w(t/|y|)}, \quad w \text{ 随位置递增}$$

改动：W · L
公式：结构示意
边界：位置是结构代理；训练不需要逐次做 branch intervention，非精确可靠性标签。

LGR / Supervision Fidelity Decay

认知：学生前缀越长，teacher 的纠正能力可能越弱，不能默认后段监督始终有效。

方法：对候选 token 看一步后 teacher confidence，构造组相对奖励，并用 entropy-triggered tree attention 控制开销。

$$r_t(a) \propto \mathrm{Conf}_T(h_t a)$$

改动：T · A · W · L
公式：结构示意
边界：下一步置信度是监督强度代理，不等于最终答对概率。

TrOPD

认知：teacher/student 分歧很大时，先判断哪些局部监督值得信任。

方法：按解码一致性选择可靠区域，outlier 区用 clipping、mask 或 FKL，并加入 teacher-prefix guidance。

$$L = m_t \ell_{\text{trusted}} + (1 - m_t)\ell_{\text{outlier}} + \lambda \ell_{\text{teacher-prefix}}$$

改动：H · F · W · C
公式：结构示意
边界：与 TOP-D 是两篇论文；这里 trust region 指监督可靠区域，不是同一个插值目标。

CoTrek

认知：它属于长 CoT 的 OPD 扩展问题，具体加速机制需要正文确认。

方法：本地缺少 PDF，暂不补写算法。

关键公式待正文核对

改动：H · L
公式：待核对
边界：不能仅根据 scalable 推断一定是截断、压缩或异步。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

CoPD / Co-Evolving Policy Distillation

认知：专家还在训练时就互相教，可能比专家完全分化后再合并更容易吸收。

方法：并行 RLVR 训练领域专家，同时进行双向 OPD，使能力与行为模式共同演化。

$$\{T_j^{(k+1)}\}_j \leftarrow \mathrm{RLVR} + \mathrm{mutual\ OPD}(\{T_j^{(k)}\}_j)$$

改动：T · C
公式：结构示意
边界：是训练结构改变，不能归为只修改某个 token 权重。

VPD / Variational Policy Distillation

认知：会阅读反馈的 teacher 也需要继续进步，固定的反馈解释能力可能成为瓶颈。

方法：用变分 EM：E-step 根据结果与语言反馈更新 teacher，M-step 蒸馏给 student。

$$T_{k+1} \leftarrow \text{E-step}(R, \text{feedback})$$
$$S_{k+1} \leftarrow \text{M-step}(T_{k+1})$$

改动：T · C · A
公式：结构示意
边界：不是单纯把反馈字符串加进固定 teacher prompt。

Rethinking OPSD

认知：teacher 看答案后不再需要探索，但 student 仍需要；这种偏好未必适合长思考。

方法：改变特权信息和生成预算，分析 fork suppression、纠错与分支行为。

$$\Delta_t = \log T(y_t|h_t, z) - \log S(y_t|h_t)$$

改动：T · W · L
公式：原文诊断量
边界：诊断论文，没有一个已经验证的通用修复算法。

OPHSD / Harness Self-Distillation

认知：额外推理流程可以只在训练中当脚手架，再把它的帮助内化到模型里。

方法：用当前模型加 draft–verify、plan–solve harness 构造 teacher，再在学生轨迹上蒸馏。

$$T = \mathrm{Harness}(S)$$
$$L = \mathbb{E}_{h\sim d_S} D(T_h \| S_h)$$

改动：T
公式：结构示意
边界：部署时能否移除 harness 取决于任务与实际内化效果。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

RWOPD / NL-to-SVA

认知：语法像标准答案还不够，应让真正性质等价的 SVA 决定哪些监督值得用。

方法：用 SymbiYosys+Z3 的性质等价检查器筛选学生 rollout，再做奖励加权 FKL。

$$L = \mathbb{E}_{y\sim S}\left[w_{\mathrm{PEC}}(y)\sum_t D_{\mathrm{KL}}(T_t \| S_t)\right]$$

改动：A · W
公式：结构示意
边界：奖励权重与验证器可用性相关；这是 rollout 加权，不等于 AOPD 动作 advantage。

d-OPSD / Self Future dLLMs

认知：扩散语言模型的监督单位应跟去噪步骤对齐，而不是硬套自回归前缀。

方法：以自生成答案作 suffix 条件构造 self-teacher，在学生去噪轨迹上做 step-level distillation。

$$L = \mathbb{E}_{s_k\sim S}\sum_k D\Big(T(\cdot|s_k,\mathrm{suffix}), S(\cdot|s_k)\Big)$$

改动：T · I
公式：结构示意
边界：这里的 step 不是左到右的 token 位置；与图像 D-OPSD 不同。

PRISM / Black-box Multimodal RL

认知：拿不到 teacher logits 时，也可以先对齐响应分布再做 RL。

方法：在 SFT 与 RLVR 之间插入 response-level adversarial alignment，用感知/推理 MoE discriminator 提供信号。

$$\mathrm{SFT} \rightarrow \text{adversarial pre-alignment} \rightarrow \mathrm{RLVR}$$

改动：T · F · C
公式：原文流程式
边界：属于黑盒、响应级对齐，不能塞进普通逐 token KL 的同一实现。

Fewer Tokens, Fewer Layers

认知：视觉输入 token 数与模型层数，也会影响蒸馏后的推理成本。

方法：题名提到 vision token pruning 与 OPD；未取得正文，不写具体剪枝规则。

关键公式待正文核对

改动：I · L
公式：待核对
边界：视觉 token 数与回答 token 长度应分开记录。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

VC-OPD

认知：teacher偏好的token不一定依赖图像；应更多学习由真实视觉证据支撑的决策。

方法：在相同学生前缀上用原图和损坏图各评分一次，图像条件下的teacher决定方向，反事实概率差经sigmoid与权重和归一化后调节力度。

$$\Delta_t = \log p_T^+(y_t) - \log p_T^-(y_t)$$
$$w_t = \sigma((\Delta_t - \tau_v)/T_v)$$
$$\bar{w}_t = \frac{N w_t}{\sum_j w_j + \epsilon}$$
$$A_t^{VC} = \bar{w}_t \widetilde{A}_t^{dir}$$

改动：T · W · N
公式：arXiv:2610.14939v1 Eq.9–12，合并展示
边界：扰动差是视觉依赖的代理，不是严格因果效应；原OpenReview版本未核对。

Vision-OPD

认知：同一个模型放大关键区域后看得更清楚，这种感知优势可以教给看全图的student。

方法：裁剪区域作 privileged teacher 输入，全图 student 生成 rollout，再匹配两者分布。

$$T_t = S_{\bar{\theta}}(\cdot|x, I_{\text{crop}}, y_{<t})$$
$$S_t = S_\theta(\cdot|x, I_{\text{full}}, y_{<t})$$

改动：T
公式：原文机制
边界：模型不一定更大；核心是输入信息差。区域获取也需要说明。

VA-OPD / Visual Advantage

认知：真正视觉相关的 token 很少，按所有语言 token 平均会稀释视觉监督。

方法：比较 teacher 有/无精细视觉的 logprob，重加权 rollout，并分高低 VA 两组分别平均 KL。

$$v_t = \log T(y_t|I_{\text{fine}}, h_t) - \log T(y_t|I_{\text{coarse}}, h_t)$$
$$L = L_{\text{highVA}} + L_{\text{lowVA}}$$

改动：T · W · N
公式：原文核心机制
边界：VA 是输入干预的概率变化，不是 RL 的 Q−V；组大小归一化是关键。

GUI-SD

认知：GUI 定位需要把监督集中到可靠且影响坐标的数字位置。

方法：teacher 看目标 bounding box 与 Gaussian soft mask，按数字位意义及 teacher confidence 加权。

$$L = \sum_t w_{\text{digit}}(t)\, w_{\text{conf}}(t)\, D(T_t \| S_t)$$

改动：T · W · I
公式：结构示意
边界：target 区域只供训练 teacher；confidence 仍是代理。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

D-OPSD / Few-step Image Diffusion

认知：少步扩散模型继续学新概念时，应沿自己的少步轨迹监督，避免破坏原生成方式。

方法：student 仅看文本，self-teacher 同时看文本与目标图像特征，匹配学生 rollout 上的预测。

$$L = \mathbb{E}_{z_k \sim S} \sum_k D\Big(T_k(\cdot|\text{text},\text{image}), S_k(\cdot|\text{text})\Big)$$

改动：T · I · H
公式：结构示意
边界：图像扩散轨迹不是文本 CoT；具体预测对象以原文为准。

On-Policy Hindsight / Early Risk

认知：未来信息可以作为训练中的 hindsight，但部署时只能用当时可见信息。

方法：这是题名层面的归类；正文不可读，具体 teacher 条件及损失待核对。

关键公式待正文核对

改动：T
公式：待核对
边界：不把其他 search hindsight 论文当作这篇。

OPSD / Self-Distilled Reasoner

认知：同一个模型看到参考解法后，可以给只看题目的自己提供更好的局部指导。

方法：student 生成回答，带 verified reasoning traces 等 privileged context 的 self-teacher 在同一前缀打分。

$$T_t = \pi_{\bar{\theta}}(\cdot|x, z, y_{<t})$$
$$S_t = \pi_\theta(\cdot|x, y_{<t})$$

改动：T
公式：原文机制式
边界：teacher 看答案有帮助不等于所有偏好都适合 student；z 在测试时不存在。

ReDraft

认知：新任务几乎不会做时，先把学生回答修订成它能学的正确文本，可能更容易起步。

方法：参考专家答案修订错误学生回答，只保留验证通过的结果，随后做 SFT。

$$L_{\text{ReDraft}} = -\sum_t \log S_\theta(y_t^{\text{revised}}|x, y_{<t}^{\text{revised}})$$

改动：D · H · F
公式：结构示意
边界：使用修订前缀的 SFT，不是学生原前缀上的 OPD loss。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

PIVOT

认知：全部失败时，最终奖励不给差异；失败诊断可以形成额外的 teacher 监督。

方法：Analyzer 定位预算下的 pivot，teacher 利用诊断重打分失败轨迹，联合 GRPO 与门控 OPD。

$$L = L_{\text{GRPO}} + \lambda\, m_{\text{confidence}} L_{\text{OPD}}(T_{\text{diagnosis}}, S)$$

改动：T · W · A
公式：结构示意
边界：pivot 是预算下首次不可恢复动作；训练不只更新 pivot 那一个 token。

Dr.OPD

认知：teacher 纠正信号是否值得加强，要看它与任务奖励提升方向是否一致。

方法：用 token 蒸馏梯度与奖励梯度的内积近似双层优化权重，借 JVP 计算后加权 divergence。

$$c_t = g_t^{\text{OPD}\,\top} \hat{g}_R$$

$$w_t \approx \text{clip}\left(1 + \lambda \frac{c_t}{\text{RMS}(c)}\right)$$

改动：W · A · C
公式：结构示意，权重机制
边界：权重来自近似梯度对齐，不是直接替换 token 或真实反事实 advantage。

CorrGRPO

认知：多奖励时，advantage 的分母也会决定学习强度；相关性与数值尺度应分开看。

方法：保留中心化总奖励分子，把总奖励方差中的协方差项换成 Pearson 相关系数。

$$\widehat{A}_i = \frac{\sum_l (R_i^l - \bar{R}^l)}{\sqrt{\sum_{l,m} \widehat{\rho}_{lm} + \epsilon}}$$

改动：N
公式：原文核心式
边界：分子仍有尺度；不自动提供 token credit，也不解决全同奖励组。

RLCSD

认知：看参考后改变的很多只是风格；正确/错误参考作对照，更可能留下内容信号。

方法：正负参考使用相同模板，取 teacher logprob 对比，以 tanh 调制 GRPO advantage 并保持原奖励符号。

$$e_t = \log T_+(y_t|h_t) - \log\left[\frac{1}{K}\sum_k T_{-,k}(y_t|h_t)\right]$$

改动：T · A · W
公式：原文核心式
边界：丢弃全对/全错组；错误轨迹的 token 不因对比信号变成正 advantage。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

Draft-OPD

认知：投机解码的 draft 错误不能只被最终正确文本覆盖，必须保留被拒绝的提议来学。

方法：target 辅助稳定主轨迹，从 anchor 重放 draft block；accepted 用 FKL、rejected 用位置衰减 RKL。

$$\mathcal{L} = \tfrac{1}{2}\Big[\mathrm{mean}_{\mathrm{acc}}\, D_{\mathrm{KL}}(T\|S) + \mathrm{wmean}_{\mathrm{rej},\gamma^{k-1}}\, D_{\mathrm{KL}}(S\|T)\Big]$$

改动：H · F · W · I · L
公式：原文核心式简写
边界：draft block 是投机提议单位，目标是接受长度与加速，非 AC2 的价值 chunk。

DF-OPD

认知：题目很少也能产生很多不同前缀；teacher 可以先自己出题再教 student。

方法：teacher 无外部 seed 出固定题库，student 反复采样，蒸馏目标保持不变。

$$D_{\mathrm{external}} \longrightarrow D_T$$
$$L_{\mathrm{OPD}} \text{ 保持不变}$$

改动：D
公式：原文机制式
边界：64 题足够仅是所测配置的观察；不意味着少算力或没有预训练知识。

AOPD

认知：teacher 喜欢的动作，应按当前 student 沿这一步能否成功来评价。

方法：把 student advantage 加权的 teacher 目标，改写为终局奖励乘概率比项与 teacher 分布项之差。

$$\widehat{J} = \frac{R-b}{H}\sum_t \Bigg[\frac{T(a_t \mid h_t)}{S(a_t \mid h_t)} \log S_\theta(a_t \mid h_t) - \mathbb{E}_{a\sim T} \log S_\theta(a \mid h_t) \Bigg]$$

改动：A · F · W · N
公式：原文未截断估计器
边界：没有显式逐 token advantage 标签；双边截断后是另一个加权目标，理论保证是精确 proximal 条件。

AC2

认知：critic 足够可靠时，不需要完整 rollout 也能得到任务训练信号。

方法：从同一 replay prefix 采样多个新 chunk，可靠题用末端 critic value，其他题及抽查组用终局评分。

$$v_i = \begin{cases} R_i, & \text{complete/audit} \\ V(sc_i), & \text{partial, ready} \end{cases}$$
$$\widehat{A}_i = v_i - \bar{v}$$

改动：H · A · N · C · L
公式：原文核心式
边界：需要训练及校验 critic；主实验无 std 分母，chunk 内仍共用 advantage。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

STOPD

认知：局部 OPD 不必等回答结束；随机截断的后段缺失可以用逆概率加权补偿。

方法：随机停止 block，以 token 保留概率的倒数加权 loss，用上一步估计 token 数作为本步分母。

$$p_t = \frac{L - K\lfloor (t-1)/K \rfloor}{L}$$
$$\widehat{G} = \sum_{i,t \le M_i} \frac{h_{i,t}}{p_t}$$
$$\mathbb{E}_S[\widehat{G}] = G$$

改动：H · W · N · L
公式：原文核心式，1-based token
边界：保持局部梯度和；归一化仍有 N/C 尺度差异，不适用于依赖未生成未来的局部 loss。

DN-MOPD

认知：老师分配正确还不够；跨领域反馈尺度失衡会让一个领域压过其他领域。

方法：按 pooled/domain log-ratio 标准差比缩放领域 advantage；不减均值，沿用 clipped 更新。

$$w_d = \mathrm{clip}(\sigma_{\mathrm{all}}/\sigma_d, 0.25, 4)$$
$$\widetilde{A}_t = \mathrm{sg}[w_d A_t]$$

改动：W · N
公式：原文核心式（统一符号）
边界：域级尺度不是 token 价值；不保证梯度范数相等。固定权重在部分尺寸已接近动态方法。

DIAL-OPD

认知：大分歧未必值得学；两个模型都低概率的位置也会出现很大的 log-ratio。

方法：插值相对分歧与绝对概率差以选 top-K token；选中后保留原始 signed log-ratio 更新。

$$s_\beta = |\log(q/p)|^{1-\beta} |q-p|^\beta$$
$$m_t = \mathbf{1}\{t \in \mathrm{TopK}(s_\beta)\}$$

改动：W · N · L
公式：原文核心式（统一符号）
边界：选择分数改变，最终 reward 未替换；完整 rollout 仍生成。概率支持不是因果重要性。

PowerOPD

认知：相同比值的低概率分歧不该同样强；直接设计教学系数的概率几何。

方法：用有界、保符号的幂概率差替代 log-ratio；alpha 调整绝对概率区域的学习强度。

$$r_t = \mathrm{sg}[q_t^\alpha - p_t^\alpha] \in [-1, 1]$$
$$\mathcal{L} = -Z^{-1} \sum_t r_t \log p_{\theta,t}$$

改动：A · F · W
公式：原文核心式（统一符号）
边界：没有构造插值分布；不是原始 KL 的同一梯度。缩放和相对权重一起改变。

一眼抓住方法：认知 → 改动位置 → 关键公式

所有公式均为 draw.io 原生 LaTeX / MathJax 标签；结构示意与原文公式分别标注。

DuoOPD

认知：学生已经做对时保护成功；学生做错且老师做对时，用老师已验证的答案支持纠错。

方法：学生验证结果决定更新系数的正负；师生四种联合结果决定原始评分、参考条件评分或同任务共享正权重。

$$A_{i,t} = (2r_{S,i} - 1)m_{i,t}, \quad m_{i,t} > 0$$

$$\mathcal{L} = -\frac{1}{B}\sum_{i}\frac{1}{T_i}\sum_{t}\mathrm{sg}[A_{i,t}]\log \pi_\theta(o_{i,t} \mid q_i, o_{i,<t})$$

改动：T · A · W · N
公式：原文 Eq.4 / Eq.8，正权重分支见本地解读
边界：改变原始OPD目标；需要完整回答验证，不能据此认定识别了每个关键token。

同一研究分支：如何重新决定 teacher–student 分歧的教学强度

共享动机不意味着算法等价：分布插值、系数变换、token 选择、领域尺度，是不同操作。

共同更新框架（局部信号）

$$g = Z^{-1} \sum_t \mathrm{sg}[m_t w_t f(p_t, q_t)] \nabla \log p_{\theta,t}$$

p：student token 概率；q：teacher token 概率；m：是否保留；w：额外权重

TOP-D｜混合分布

$$q_\lambda = (1-\lambda)p + \lambda q$$

$$f = \log(1 - \lambda + \lambda q/p)$$

负向有下界；只依赖概率比
完整算法还有 return、标准化与内部迭代

PowerOPD｜变换系数

$$f = q^\alpha - p^\alpha \in [-1, 1]$$

$$f(\epsilon p, \epsilon q) = \epsilon^\alpha f(p, q)$$

直接考虑绝对概率尺度
没有构造归一化的插值 teacher

DIAL-OPD｜选择 token

$$s_\beta = |\log(q/p)|^{1-\beta} |q-p|^\beta$$

$$f_{\text{effective}} = m_t \log(q/p)$$

插值的是选词分数；选中后仍用 log-ratio
完整 rollout 仍需生成和评分

DN-MOPD｜校准领域尺度

$$w_d = \mathrm{clip}(\sigma_{\text{all}}/\sigma_d, 0.25, 4)$$

$$f_{\text{effective}} = w_d \log(q/p)$$

领域内同乘正数，保持正负号与排序
不是 token 重要性判断

最直接的重合：DIAL 的选词分数 = Power 的系数幅度

$$s_{\text{DIAL},\beta=1} = |q-p| = |r_{\text{Power},\alpha=1}|$$

一个据此选择位置，一个直接据此加权；即便 DIAL 保留全部位置，也回到 vanilla OPD。

共同边界：概率分歧 / 支持度 ≠ 对最终正确率的因果贡献
已做：插值、幂变换、稀疏监督、领域缩放。
这几篇尚未直接解决：高概率风格偏好是否值得学？低概率修复动作是否关键？
新 idea 若围绕任务收益，需要继续对照 AOPD、PIVOT、CC-OPD 等工作。